

MAF: 特徴空間の Mahalanobis 幾何に基づく野生動物画像の Ultra-Near-OoD 検知

d-hacks B3.0 omote / 親:zackey さん

概要

本稿では、野生動物画像における超近接 OOD (Ultra-Near-OoD) 検知を対象として、Mahalanobis Affinity Fusion (MAF) を提案する。Ultra-Near-OoD は、NINCO や SSB-hard のような既存の Near-OOD 設定よりも、ID 種と OOD 種が同一ドメイン内で形状・模様・姿勢・背景を強く共有するため、未知種の棄却がさらに難しい設定として定義する。MAF は、凍結済みの特徴抽出器 (backbone) の特徴空間で各 ID クラスへの Mahalanobis 距離を計算し、距離に基づく softmax (distance softmax) により得られる最近傍クラス確信度と正規化エントロピーの補数を幾何融合する学習後適用型 (post-hoc) 手法である。自作した WILD_DATA を用いた評価では、DINOv2-ViT-B/14 の凍結特徴上で MAF は既存手法より高い AUROC と低い FPR95 を示した。本研究は、Ultra-Near-OoD において分類器のロジット (logit) だけでなく、特徴空間のクラス条件付き幾何を利用することの有効性を示す。

1 序論

1.1 背景

深層画像分類器は、訓練時に観測したクラス集合に属する入力に対して高い識別性能を示す一方で、訓練時に観測していない入力に対しても高い確信度を出すことがある。この問題は分布外検知 (out-of-distribution detection; OOD detection) として研究されており、安全な機械学習システムを構築するうえで重要である。特に野生動物画像認識では、カメラトラップ、ドローン、個人端末などから多様な画像が得られ、分類器にとって未知の種が実運用時に出現しやすい。既知種のみを分類対象として学習した分類器が未知種を既知種として受理すると、生態調査、個体数推定、保全活動における下流判断へ誤差が伝播する。

OOD 検知の代表的な学習後適用型 (post-hoc) 手法として、最大 softmax 確率 (maximum softmax probability; MSP) [1], エネルギースコア (Energy score) [2], 最大ロジット (MaxLogit) [3], Mahalanobis 距離に基づく手法 [4], 相対 Mahalanobis 距離 (Relative Mahalanobis Distance; RMD) [5], KNN [6], ViM [7], ReAct [8], DICE [9], ASH [10], GEN [11], SCALE [12] などがある。これらは追加の OOD 訓練データを必要としない、または既存の分類器出力を再利用できるため、実装コストの低い検知器として広く使われる。

1.2 課題

本稿が扱う課題は、ID 種と OOD 種が同じ野生動物ドメインに属し、形状、模様、姿勢、生息環境が極めて近い超近接 OOD (Ultra-Near-OoD) 検知である。本稿では Ultra-Near-OoD を、NINCO や SSB-hard のような既存の Near-OOD ベンチマークよりもさらに厳しい条件、すなわち既知種と未知種が同一の野生動物ドメイン内にあり、背景・撮影条件・体型・模様・姿勢を強く共有するため、分類器が未知種を既知種として受理しやすい設定として定義する。図 1 に概念図を示す。遠方 OOD (Far-OOD) では画像の統計や意味が大きく異なるため、ロジット (logit) や softmax に基づく単純なスコアでも比較的検出しやすい場合がある。しかし Ultra-Near-OoD では、未知種がある ID クラスに視覚的に近く、分類器が高い確信度 (confidence) を出しやすい。たとえば、leopard は cheetah に、wildebeest は buffalo に、rhino は hippo や buffalo に近く配置される可能性がある。このとき、最大ロジットや最大 softmax 確率のみを見るスコアは、「最も近い ID クラスへの近さ」を過大評価しやすい。

図 1 のようにユークリッド距離で見ると、OOD が ID クラスの近傍または中間に入るだけで、単純な距離や softmax 確信度では棄却しにくくなる。一方、Mahalanobis 距離は特徴空間におけるクラス条件付き分布を明示的に扱うため、クラス平均からの距離だけでなく特徴次元間の分散と相関を考慮できる。すなわち、ID 内で自然に広がる方向と、ID 分布から外れやすい方向を区別して距離を測れる点に意義がある。しかし、従来の Mahalanobis 距離に基づく OOD スコア




図 1: Near-OOD 設定の概念図. ここでは直感的説明のため、特徴空間をユークリッド空間として描いている.

(Mahalanobis OOD score) は、最小距離や指数和対数 (log-sum-exp) など単一の距離集約に依存しやすく、距離ベクトル全体が持つ相対的な分布形状を十分に利用しない. Ultra-Near-OoD では、ある 1 クラスには近いが他の ID クラスとの距離分布全体では ID らしくない入力が存在する. したがって、最小距離だけでなく、全 ID クラスへの距離関係をスコア化する必要がある.

1.3 先行研究の問題

MSP, Entropy, Energy, MaxLogit などの softmax/ロジット系スコアは、分類ヘッドの出力を利用する. これらのスコアは簡便であり、大規模設定でも扱いやすい. しかし、分類ヘッドは ID クラスを識別するように学習されるため、ID クラス間の決定境界付近や近接 OOD に対して高いロジットを出すことがある. ReAct, ASH, DICE, SCALE は内部活性や重みを整形し、過剰確信 (overconfidence) を抑制する方向の学習後適用型手法であるが、本研究の WILD_DATA 設定では局所分類器への適用として評価されるため、公式 ImageNet 分類器をそのまま使った比較とは異なる.

Mahalanobis 系手法は、クラスごとの特徴分布をガウス分布で近似して判別する枠組み (Gaussian discriminant analysis; GDA) の仮定に基づいてクラス条件付き特徴分布を扱う [4]. RMD は全体分布または背景分布を表す距離 (global/background distance) を用いて Mahalanobis 距離の近接 OOD における失敗を補正する [5]. Mahalanobis++ は特徴ノルムの問題に着

目し、 ℓ_2 正規化が Mahalanobis 距離の仮定と整合しやすいことを示す [13]. これらはいずれも距離に基づくが、距離ベクトルを softmax 分布として扱い、その最大成分と正規化エントロピーの補数を幾何融合する設計は明示的には用いていない.

1.4 本論文の貢献

本稿の貢献は以下の 3 点である.

1. 凍結した特徴抽出器 (backbone) の特徴上で Mahalanobis 距離ベクトルを softmax 分布化し、確信度成分 (confidence) と一貫性成分 (consistency) を幾何融合する MAF を提案する.
2. 5 ID 種と 5 OOD 種からなる WILD_DATA の Ultra-Near-OoD 設定において、DINOv2-ViT-B/14 特徴を用いた MAF が AUROC で代表的な学習後適用型 baseline を上回ることを示す.
3. 共有共分散 (tied covariance)、生特徴 (raw feature)、幾何融合、構成成分 (score component) の各設計について要素実験 (ablation) を行い、MAF の有効性と限界を特徴空間の幾何から考察する.

2 提案手法

2.1 問題設定

ID クラス集合を $\mathcal{C} = \{1, \dots, K\}$ とする. 入力画像 x に対して、OOD 検知器はスコア $S(x)$ を出力し、閾値 γ により ID または OOD へ二値判定する. 本稿ではスコアが高いほど ID らしいと定義する. したがって、 $S(x) \geq \gamma$ で ID、 $S(x) < \gamma$ で OOD と判定する. 評価では、特定の閾値を事前には選ばずにランキング性能を測る指標 (threshold-independent metric) として AUROC を主指標に用いる. さらに、実運用上重要な誤受理率を反映する副次的な主要指標 (co-primary operational metric) として FPR95 を併記する. AUPR-IN と AUPR-OUT は、それぞれ ID および OOD を陽性クラス (positive class) とする precision-recall 曲線下面積である. FPR95 は ID true positive rate を 95% に固定したときの OOD false positive rate であり、低いほど良い.

AUTC はしきい値曲線下面積 (Area Under the Threshold Curve) であり、スコアの閾値を動かした

ときに ID/OOD の分離がどの程度悪いかを要約する補助指標である [14]. AUROC が主にスコアの順位を評価するのにに対し, AUC はスコア分布の重なりや閾値の置きにくさの影響を受ける. そのため, 本稿では AUC を閾値全体での実用的な分離の悪さを確認する指標として扱い, 低いほど良いと解釈する.

2.2 特徴抽出と統計量推定

本研究の主特徴抽出器 (backbone) は DINOv2-ViT-B/14 である [15]. DINOv2 は fine-tuning せず, 凍結特徴抽出器として用いる. 入力画像 x から 768 次元の大域 CLS 特徴 (global CLS feature) $f(x) \in \mathbb{R}^d$ を得る. 実装上, 画像は評価時に Resize(256), Center-Crop(224), ToTensor, ImageNet mean/std normalization により前処理される. ロジット系 baseline のために, ID training split のみを用いて生特徴から 5 クラス logit を出力する線形分類ヘッド (local linear classifier head) $768 \rightarrow 5$ を学習し, best checkpoint は ID validation accuracy で選択する. MAF 本体はこの分類ヘッドのロジットを使わず, 凍結 DINOv2 特徴に直接適用する.

クラス c の ID validation 特徴集合を $\mathcal{V}_c$, その平均を μ_c とする. 各クラスの共分散推定値を Σ_c とし, 本稿の固定設定では Ledoit-Wolf 型の縮小推定 [16] により正則化する. クラスごとに異なる計量を使うと, 高次元特徴では有限サンプル分散に過適合しやすい. そこで, 主設定では各クラス共分散の平均を全クラス共通の共有共分散 (tied covariance) として用いる.

$$\Sigma_{\text{tied}} = \frac{1}{K} \sum_{c=1}^K \Sigma_c. \quad (1)$$

入力 x の特徴とクラス c の平均の二乗 Mahalanobis 距離を

$$q_c(x) = (f(x) - \mu_c)^\top \Sigma_{\text{tied}}^{-1} (f(x) - \mu_c), \quad (2)$$

とする. 実装では softmax に入力する距離として二乗距離そのものではなく,

$$r_c(x) = \sqrt{\max(q_c(x), 0)}, \quad (3)$$

を用いる. これにより数値誤差により $q_c(x)$ がわずかに負になる場合にも安定に処理できる.

2.3 距離 softmax 分布

MAF は, 最近傍クラスへの絶対距離だけではなく, 全 ID クラスへの距離ベクトル $\mathbf{r}(x) = (r_1(x), \dots, r_K(x))$ を利用する. 温度 τ を用いて,

$$p_c(x; \tau) = \frac{\exp(-r_c(x)/\tau)}{\sum_{j=1}^K \exp(-r_j(x)/\tau)}, \quad (4)$$

を定義する. これは分類器のロジット (logit) に対する softmax ではなく, Mahalanobis 距離から構成するクラス相対分布である. 距離が小さいクラスほど大きい確率を持つ. 本稿の固定設定では $\tau = 1.0$ とする.

この分布から, 最近傍 ID クラスへの集中度を

$$\text{conf}(x) = \max_{c \in \mathcal{C}} p_c(x; \tau), \quad (5)$$

と定義する. $\text{conf}(x)$ は距離 softmax 上の最大確率 (distance-softmax maximum probability) であり, 最近傍クラスに対する Mahalanobis 確信度と解釈できる. 一方, 分布全体のエントロピーの低さを表す一貫性成分 (consistency) を正規化エントロピーにより定義する.

$$H_{\text{norm}}(x) = -\frac{\sum_{c=1}^K p_c(x; \tau) \log(p_c(x; \tau) + \epsilon)}{\log K}, \quad (6)$$

$$\text{cons}(x) = 1 - H_{\text{norm}}(x). \quad (7)$$

$\text{cons}(x)$ は正規化エントロピー $H_{\text{norm}}(x)$ そのものではなく, その補数 $1 - H_{\text{norm}}(x)$ に基づく一貫性スコア (consistency score) である. 低エントロピーで一つの ID クラスへ集中した分布では高くなり, 複数クラスへ広がる高エントロピーな分布では低くなる. MAF スコアでは, $\text{conf}(x)$ と $\text{cons}(x)$ を区間 $[\epsilon, 1]$ に範囲制限した値を用いる. min-max normalization, z-score, sigmoid, softplus, rank normalization は用いない.

2.4 Mahalanobis Affinity Fusion

最終的な MAF スコア (MAF score) は, $\text{conf}(x)$ と $\text{cons}(x)$ の幾何融合として定義する. ここで $\text{clip}_{[\epsilon, 1]}(z) = \min\{1, \max\{\epsilon, z\}\}$ は範囲制限 (clipping) であり, $z < \epsilon$ なら ϵ , $z > 1$ なら 1 , それ以外では z を返す.

$$S_{\text{MAF}}(x) = \left[\text{clip}_{[\epsilon, 1]}(\text{conf}(x)) \right]^\alpha \times \left[\text{clip}_{[\epsilon, 1]}(\text{cons}(x)) \right]^{1-\alpha}. \quad (8)$$




図 2: MAF の処理全体. 凍結 DINOv2 から特徴を抽出し, ID validation 特徴から推定したクラス平均 (class means) と共有共分散 (tied covariance) により距離ベクトルを得る. 距離ベクトルを softmax 分布化し, 確信度成分 (confidence) と一貫性成分 (consistency) を幾何融合する.

本稿の主結果では, DINOv2 の生特徴 (raw feature), 共有共分散 (tied covariance), Ledit-Wolf 共分散推定, $\tau = 1.0$, $\alpha = 0.50$ を固定設定とする. この固定設定を Final MAF と呼ぶ. また, ‘MAF mah.t raw’ は oracle check として扱う. ここで oracle check とは, test OOD label を用いて α または τ を選択する可能性のある確認用設定を指し, 実運用設定ではない. 固定設定と oracle check の性能差は DINOv2 ではほぼゼロであるため, 本稿の主張は固定設定に基づく.

2.5 幾何融合の性質

$u = \text{clip}_{[\epsilon, 1]}(\text{conf}(x))$, $v = \text{clip}_{[\epsilon, 1]}(\text{cons}(x))$ とおく. 幾何融合の α に関する関数は

$$\phi(\alpha) = u^\alpha v^{1-\alpha} = v \exp\{\alpha(\log u - \log v)\}. \quad (9)$$

したがって,

$$\phi''(\alpha) = \phi(\alpha)(\log u - \log v)^2 \geq 0, \quad (10)$$

が成り立つ. すなわち, $u \neq v$ であれば幾何融合は α に関して凸である. また, $0 \leq \alpha \leq 1$ では重み付き幾何平均は重み付き算術平均以下であるため,

$$u^\alpha v^{1-\alpha} \leq \alpha u + (1 - \alpha)v, \quad (11)$$

が成り立つ. この性質により, 片方の成分だけが低い入力を過大評価しにくく, 最近傍クラスへの近さと距離分布の低エントロピー性の両方を要求するスコアになる.




図 3: Mahalanobis 距離の幾何的直観. Euclidean 距離は全方向を等方に扱うが, Mahalanobis 距離は ID 特徴の分散と相関を考慮する.

3 実験

3.1 主実験: WILD_DATA 設定

主実験では, 自身が作成した野生動物画像データセット WILD_DATA/splits を用いる. WILD_DATA は Google Drive で公開しており, split と元画像の出典元は配布フォルダ内に併記している. URL は https://drive.google.com/drive/folders/1LCdZnAN6gWiv_Ds0bTWLipD6jjptLAgj?usp=sharing である. ID クラスは buffalo, cheetah, elephant, giraffe, hippo の 5 種であり, OOD クラスは impala, leopard, lion, rhino, wildebeest の 5 種である. 本研究では, ID 種と同じ野生動物ドメインに属し, 形状, 模様, 姿勢, 生息環境の点で極めて近い未知種を Ultra-Near-OoD と定義する. Far-OOD は本稿の主実験では扱わない. 使用した分割 (split) を表 1 と図 4 に示す. prepared split は事前に固定した分割を指し, 各 seed で ID validation/test を再サンプリングしない. seed は局所分類ヘッドの学習初期化や sampler に影響する. OOD validation split は本稿の評価および MAF の固定設定には使用しない.

DINOv2-ViT-B/14 では, 特徴キャッシュ (feature

分割	ID (5種)	OoD (5種)
train	buffalo 11,000 / cheetah 6,994 / elephant 11,000 / giraffe 10,000 / hippo 6,991 = 45,985 → 一部エラー & スキップで 45,941枚	なし
val	各2,000 = 10,000枚	なし
test	各2,000 = 10,000枚	impala / leopard / lion / rhino / wildebeest 各2,000 = 10,000枚

図 4: WILD_DATA の split size. train/id は配布 split 上では 5 ID 種の合計で 45,985 枚である. このうち 44 枚は画像読み込みエラーのため skip し, 実験では 45,941 枚を使用した. val/id, test/id, test/ood はいずれも 10,000 枚である. OOD validation split は本稿の評価には使用しない.

表 1: WILD_DATA における split 上の画像枚数と実験で使った画像枚数.

Split	Listed	Used
train/id	45,985	45,941
val/id	10,000	10,000
test/id	10,000	10,000
test/ood	10,000	10,000

cache) は読み込み可能な画像のみから作成し, train/id が $45,941 \times 768$, val/id が $10,000 \times 768$, test/id が $10,000 \times 768$, test/ood が $10,000 \times 768$ である. 評価時の前処理は ID と OOD で同一である. 実験に使用した計算環境を表形式で示す.

GPU 環境. 実験に使用した GPU およびソフトウェア環境.

項目	値
GPU	NVIDIA GeForce RTX 2080 Ti
VRAM	11,264 MiB/GPU
GPU 枚数	4
PyTorch	2.6.0+cu126
torchvision	0.21.0+cu126
CUDA	12.6

3.2 比較手法

比較対象は, MSP, Entropy, Energy, MaxLogit, KNN, RMD, Mah-MinDist, Mah-LSE, Mahalanobis++, GEN, ViM, ReAct, ASH-B/S/P, DICE, SCALE, NCI である. 値はすべて同じ test/id と test/ood で再評価したものであり, 既存論文から直接引用した値ではない. ただし, 手法ごとに利用する情報は同一ではない. MAF, Mahalanobis, RMD, KNN は

凍結 DINOv2 特徴 (feature) を使う. MSP, Entropy, Energy, MaxLogit は, 凍結特徴に学習した線形分類ヘッド $d \rightarrow 5$ のロジット (logits) を使う. GEN, ReAct, ASH, DICE, SCALE, ViM, NCI は局所ヘッドのロジット, 中間表現 (hidden representation), 最終全結合層 (final FC) などに適用する. したがって, 本比較は同一 split 上の再評価である一方, 手法ごとに必要な特徴やロジットへのアクセス (method-specific feature/logit access) を含む.

本稿では, 主比較表に多くの手法を載せるが, 中心的な比較対象は RMD, KNN, Energy, MaxLogit である. RMD は Mahalanobis 距離の近接 OOD 失敗を補正する強い baseline であり, KNN は分布仮定を置かない距離ベース baseline である. Energy と MaxLogit はロジットに基づく強い学習後適用型 baseline である. なお, 一部の行には診断用 (diagnostic) または OOD label を用いた oracle/tuned な hyperparameter が含まれる. そのため, 本稿では固定 MAF の性能を強調しつつ, baseline 側にも強い設定が含まれることを明記する.

3.3 統計的不確実性の扱い

本稿で報告する 3 seed 平均と標準偏差は, 固定 split 上での学習初期化や sampler に由来するばらつきを表す. prepared split は固定であり, seed ごとに ID/OOD の再分割やブートストラップ再標本化 (bootstrap resampling) は行っていない. また, MAF は凍結特徴, 固定 split, 固定 hyperparameter から計算され, 局所分類ヘッドを使わないため, DINOv2 特徴上ではほぼ決定的 (deterministic) である. したがって, MAF の標準偏差が 0.0000 になることは性能推定の不確実性が小さいことを意味するのではなく, 本実験がデータ分割やサンプリングに伴う不確実性を測っていないこ

とを意味する。結果表の標準偏差は seed 由来の実装上のばらつきとして解釈し、分割に由来する不確実性 (split uncertainty) は limitation として扱う。

3.4 補助実験: ImageNet-scale 近接 OOD

主実験とは別に, ImageNet-1K を ID とし, NINCO [17] と SSB-hard [18] を近接 OOD とする補助実験を行った。この実験では ImageNet-1K train を統計量推定に使い, ImageNet-1K validation を seed ごとに ID validation/test へ分割する。NINCO と SSB-hard の ALL-OOD 平均は dataset ごとの単純平均であり, 画像枚数で重み付けしていない。この補助実験は, MAF が得意でない条件も確認するための否定的確認および限界確認 (negative/limitation check) として位置づける。主張の中心は WILD_DATA 結果である。

4 結果

4.1 WILD_DATA における主結果

表 2 に WILD_DATA における主結果を示す。すべて 3 seed 平均 $\pm$ 標準偏差であり, 小数第五位を四捨五入して 4 桁表示する。AUROC, AUPR-IN, AUPR-OUT は高いほど良く, FPR95, AUTC は低いほど良い。固定設定の MAF は AUROC 0.8928, AUPR-IN 0.9002, AUPR-OUT 0.8793, FPR95 0.5128, AUTC 0.7734 を示す。RMD raw, val, squared に対して AUROC は+0.0223, FPR95 は-0.0379 改善する。KNN raw に対しては AUROC +0.0405, FPR95 -0.0238 である。Mahalanobis++に対しては AUROC +0.1221, FPR95 -0.2248 である。

4.2 実験 1: 古典的スコアとの比較

表 3 に, MAF と古典的 OOD スコアの比較を示す。DINOv2 では MAF が MaxLogit に対して AUROC を 0.0593 改善し, FPR95 も 0.8040 から 0.5128 へ低下した。ImageNet-ViT, OpenAI CLIP-B/16, BioCLIP でも AUROC と FPR95 の両方が改善した。一方, AUTC では一部の logit 系 score が MAF より低い値を示す。この結果から, MAF はすべての特徴抽出器で一様に全指標最良になるわけではないが, DINOv2 を中心とする複数の特徴空間で AUROC を安定に改善する。




図 5: WILD_DATA における主要手法の AUROC と FPR95 の同時比較。MAF は高い AUROC と低い FPR95 を両立する。




図 6: 特徴抽出器 (backbone) 別の AUROC 比較。MAF は DINOv2, ImageNet-ViT, OpenAI CLIP-B/16, BioCLIP で古典的スコアの代表値を上回る。CLIP と BioCLIP はそれぞれ [19, 20] に基づく特徴抽出器である。

4.3 実験 2: ablation

表 4 に, DINOv2-ViT-B/14 上の要素実験 (ablation) を示す。Final MAF は幾何融合 (geometric fusion) $\alpha = 0.50$, 共有共分散 (tied covariance), Ledoit-Wolf 推定, 生特徴 (raw feature) を用いる設定である。確認用設定 (oracle check) である MAF mah.t raw は AUROC が同じで, FPR95 が 0.0007 だけ低い。この差は小さいため, 固定 MAF を主結果にするのが安全である。

表 2: WILD_DATA における MAF と prior work/baseline の比較. 値は 3 seed 平均 $\pm$ 標準偏差. AUROC, AUPR-IN, AUPR-OUT は高いほど良く, FPR95, AUTC は低いほど良い. MAF は固定設定, 一部 baseline は diagnostic/tuned 設定を含む.

Rank	Method	Variant	AUROC $\uparrow$	AUPR-IN $\uparrow$	AUPR-OUT $\uparrow$	FPR95 $\downarrow$	AUTC $\downarrow$
1	MAF	fixed $\alpha = 0.50$, tied LW, raw	0.8928 $\pm$ 0.0000	0.9002 $\pm$ 0.0000	0.8793 $\pm$ 0.0000	0.5128 $\pm$ 0.0002	0.7734 $\pm$ 0.0000
2	RMD	raw, val, squared	0.8705 $\pm$ 0.0001	0.8720 $\pm$ 0.0001	0.8548 $\pm$ 0.0001	0.5507 $\pm$ 0.0005	0.8271 $\pm$ 0.0002
3	KNN	raw	0.8523 $\pm$ 0.0000	0.8404 $\pm$ 0.0000	0.8529 $\pm$ 0.0000	0.5366 $\pm$ 0.0000	0.7826 $\pm$ 0.0000
4	ASH-P	ASH-P	0.8398 $\pm$ 0.0311	0.8279 $\pm$ 0.0325	0.8428 $\pm$ 0.0319	0.5835 $\pm$ 0.0548	0.8698 $\pm$ 0.0141
5	ReAct	ReAct	0.8379 $\pm$ 0.0304	0.8268 $\pm$ 0.0386	0.8397 $\pm$ 0.0269	0.5743 $\pm$ 0.0443	0.8959 $\pm$ 0.0171
6	ASH-S	ASH-S	0.8357 $\pm$ 0.0310	0.8236 $\pm$ 0.0319	0.8373 $\pm$ 0.0318	0.6081 $\pm$ 0.0549	0.8746 $\pm$ 0.0122
7	SCALE	SCALE	0.8356 $\pm$ 0.0308	0.8237 $\pm$ 0.0313	0.8367 $\pm$ 0.0313	0.6090 $\pm$ 0.0532	0.8890 $\pm$ 0.0233
8	MaxLogit	MaxLogit, Linear(768 $\rightarrow$ 5)	0.8335 $\pm$ 0.0060	0.8578 $\pm$ 0.0080	0.7769 $\pm$ 0.0101	0.8040 $\pm$ 0.0141	0.7745 $\pm$ 0.0050
9	Energy	Energy, Linear(768 $\rightarrow$ 5)	0.8330 $\pm$ 0.0061	0.8575 $\pm$ 0.0080	0.7768 $\pm$ 0.0107	0.8025 $\pm$ 0.0174	0.7706 $\pm$ 0.0055
10	Entropy	Entropy, Linear(768 $\rightarrow$ 5)	0.8314 $\pm$ 0.0025	0.8537 $\pm$ 0.0026	0.7784 $\pm$ 0.0045	0.7952 $\pm$ 0.0081	0.8055 $\pm$ 0.0159
11	MSP	MSP, Linear(768 $\rightarrow$ 5)	0.8307 $\pm$ 0.0023	0.8532 $\pm$ 0.0024	0.7761 $\pm$ 0.0045	0.7894 $\pm$ 0.0069	0.8340 $\pm$ 0.0118
12	ViM	diagnostic	0.8305 $\pm$ 0.0191	0.8282 $\pm$ 0.0304	0.8258 $\pm$ 0.0152	0.6151 $\pm$ 0.0199	0.9646 $\pm$ 0.0606
13	Mah-MinDist	euclidean	0.8233 $\pm$ 0.0000	0.8520 $\pm$ 0.0000	0.7884 $\pm$ 0.0000	0.7445 $\pm$ 0.0000	0.7984 $\pm$ 0.0000
14	GEN	GEN	0.7908 $\pm$ 0.0135	0.7946 $\pm$ 0.0150	0.7455 $\pm$ 0.0109	0.8273 $\pm$ 0.0070	0.6845 $\pm$ 0.0316
15	Mahalanobis++	L2 MinDist	0.7707 $\pm$ 0.0000	0.7380 $\pm$ 0.0000	0.7594 $\pm$ 0.0000	0.7376 $\pm$ 0.0000	0.9060 $\pm$ 0.0000
16	DICE	DICE	0.7664 $\pm$ 0.0156	0.7733 $\pm$ 0.0058	0.7046 $\pm$ 0.0127	0.8769 $\pm$ 0.0153	0.8242 $\pm$ 0.0159
17	ASH-B	ASH-B	0.7538 $\pm$ 0.0218	0.7275 $\pm$ 0.0205	0.7480 $\pm$ 0.0200	0.7575 $\pm$ 0.0225	0.9222 $\pm$ 0.0136
18	NCI	NCI	0.6930 $\pm$ 0.0150	0.7014 $\pm$ 0.0131	0.6494 $\pm$ 0.0106	0.8856 $\pm$ 0.0056	0.9196 $\pm$ 0.0031

表 3: 各特徴抽出器 (backbone) における MAF と古典的 OOD スコアの比較. 値は 3 seed 平均 $\pm$ 標準偏差. FPR95 と AUTC は低いほど良い.

Backbone	Method	AUROC $\uparrow$	AUPR-IN $\uparrow$	AUPR-OUT $\uparrow$	FPR95 $\downarrow$	AUTC $\downarrow$
DINOv2	MAF $\alpha = 0.50$	0.8928 $\pm$ 0.0000	0.9002 $\pm$ 0.0000	0.8793 $\pm$ 0.0000	0.5128 $\pm$ 0.0002	0.7734 $\pm$ 0.0000
DINOv2	MaxLogit	0.8335 $\pm$ 0.0060	0.8578 $\pm$ 0.0080	0.7769 $\pm$ 0.0101	0.8040 $\pm$ 0.0141	0.7745 $\pm$ 0.0050
ImageNet-ViT	MAF $\alpha = 0.50$	0.8426 $\pm$ 0.0000	0.8606 $\pm$ 0.0000	0.8126 $\pm$ 0.0000	0.6777 $\pm$ 0.0016	0.8260 $\pm$ 0.0001
ImageNet-ViT	Energy	0.8157 $\pm$ 0.0048	0.8224 $\pm$ 0.0044	0.7831 $\pm$ 0.0138	0.7540 $\pm$ 0.0323	0.8266 $\pm$ 0.0045
OpenAI CLIP-B/16	MAF $\alpha = 0.50$	0.8291 $\pm$ 0.0000	0.8364 $\pm$ 0.0000	0.8062 $\pm$ 0.0000	0.6824 $\pm$ 0.0001	0.8274 $\pm$ 0.0000
OpenAI CLIP-B/16	Energy	0.7725 $\pm$ 0.0012	0.7882 $\pm$ 0.0017	0.7240 $\pm$ 0.0013	0.8208 $\pm$ 0.0039	0.8401 $\pm$ 0.0009
BioCLIP	MAF $\alpha = 0.50$	0.8025 $\pm$ 0.0000	0.8154 $\pm$ 0.0000	0.7728 $\pm$ 0.0000	0.7280 $\pm$ 0.0001	0.8570 $\pm$ 0.0000
BioCLIP	Energy	0.7967 $\pm$ 0.0026	0.8131 $\pm$ 0.0022	0.7416 $\pm$ 0.0035	0.8273 $\pm$ 0.0029	0.8211 $\pm$ 0.0023




図 7: ablation における AUROC. 共有共分散 (tied covariance) と raw feature を用いた幾何融合が最も安定して高い.

4.4 補助実験: ImageNet-1K/NINCO/SSB-hard

表 5 に ImageNet-scale 補助実験の ALL-OOD 平均を示す. この設定では ViM が AUROC 0.8828, FPR95 0.4096 で最も良い. MAF は AUROC 0.8135 であり, WILD_DATA のように AUROC 最上位ではない. 一方, AUTC では MAF が 0.5840 と低い. これはランキング性能では ViM や Mahalanobis++ に劣るが, 閾値全体を見た補助指標では MAF スコアの分布が有利で




図 8: ablation における FPR95. Euclidean 距離やクラス別共分散 (class-wise covariance) では FPR95 が大きく悪化する.

ある可能性を示す. ただし, この実験は oracle/tuned 設定を含む行を含み, 実運用性能としては慎重に解釈する必要がある.

表 4: DINOv2-ViT-B/14 における要素実験 (ablation). 値は 3 seed 平均 $\pm$ 標準偏差. MAF($\alpha = 0.50$) は固定値であり, test OOD label で選んだ値ではない. oracle check は確認用設定であり, 主張の中心にしない.

Group	Variant	AUROC $\uparrow$	AUPR-IN $\uparrow$	AUPR-OUT $\uparrow$	FPR95 $\downarrow$	AUTC $\downarrow$
Final MAF	MAF($\alpha = 0.50$ fixed, $\tau = 1.0$ fixed), tied LW, raw	0.8928 $\pm$ 0.0000	0.9002 $\pm$ 0.0000	0.8793 $\pm$ 0.0000	0.5128 $\pm$ 0.0002	0.7734 $\pm$ 0.0000
Oracle check	MAF mah.t raw	0.8928 $\pm$ 0.0000	0.9002 $\pm$ 0.0000	0.8793 $\pm$ 0.0000	0.5121 $\pm$ 0.0008	0.7731 $\pm$ 0.0003
Component	cons(x) only, tied LW	0.8921 $\pm$ 0.0000	0.8995 $\pm$ 0.0000	0.8788 $\pm$ 0.0000	0.5171 $\pm$ 0.0004	0.8089 $\pm$ 0.0000
Normalization	MAF mah.t L2	0.8912 $\pm$ 0.0000	0.8996 $\pm$ 0.0000	0.8765 $\pm$ 0.0000	0.5223 $\pm$ 0.0003	0.7885 $\pm$ 0.0001
Fusion	arithmetic fusion $\alpha = 0.50$, tied LW	0.8905 $\pm$ 0.0000	0.8984 $\pm$ 0.0000	0.8744 $\pm$ 0.0000	0.5307 $\pm$ 0.0004	0.7718 $\pm$ 0.0000
Component	conf(x) only, tied LW	0.8854 $\pm$ 0.0000	0.8940 $\pm$ 0.0000	0.8670 $\pm$ 0.0000	0.5622 $\pm$ 0.0002	0.7401 $\pm$ 0.0000
Baseline	Mah-LSE euc raw	0.8231 $\pm$ 0.0000	0.8514 $\pm$ 0.0000	0.7898 $\pm$ 0.0000	0.7342 $\pm$ 0.0002	0.7962 $\pm$ 0.0000
Distance	MAF euclidean raw	0.8096 $\pm$ 0.0000	0.8570 $\pm$ 0.0000	0.7319 $\pm$ 0.0000	0.8576 $\pm$ 0.0002	0.7184 $\pm$ 0.0000
Covariance	MAF mah.c raw	0.7691 $\pm$ 0.0000	0.7928 $\pm$ 0.0000	0.7219 $\pm$ 0.0000	0.8335 $\pm$ 0.0001	0.7308 $\pm$ 0.0000
Covariance	geometric fusion $\alpha = 0.50$, class-wise LW	0.7495 $\pm$ 0.0000	0.7692 $\pm$ 0.0000	0.6989 $\pm$ 0.0000	0.8574 $\pm$ 0.0003	0.9162 $\pm$ 0.0000

表 5: ImageNet-1K/NINCO/SSB-hard 補助実験の ALL-OOD 平均. dataset ごとの単純平均であり, 画像枚数重み付き平均ではない. Rank は AUROC 順である. MAF は AUROC 最良ではないが, AUTC が最も低い.

Rank	Method	Backbone/access	AUROC $\uparrow$	AUPR-IN $\uparrow$	AUPR-OUT $\uparrow$	FPR95 $\downarrow$	AUTC $\downarrow$
1	ViM	local logits/features	0.8828 $\pm$ 0.0002	0.8758 $\pm$ 0.0001	0.8727 $\pm$ 0.0002	0.4096 $\pm$ 0.0004	0.7781 $\pm$ 0.0001
2	Mahalanobis++	L2 DINOv2 feature	0.8654 $\pm$ 0.0001	0.8674 $\pm$ 0.0001	0.8445 $\pm$ 0.0003	0.4602 $\pm$ 0.0002	0.7967 $\pm$ 0.0019
3	MaxLogit	local logits	0.8518 $\pm$ 0.0003	0.8550 $\pm$ 0.0002	0.8109 $\pm$ 0.0003	0.5323 $\pm$ 0.0007	0.8081 $\pm$ 0.0063
4	GEN	local logits	0.8512 $\pm$ 0.0003	0.8536 $\pm$ 0.0002	0.8086 $\pm$ 0.0003	0.5379 $\pm$ 0.0010	0.7245 $\pm$ 0.0026
5	Energy	local logits	0.8498 $\pm$ 0.0003	0.8535 $\pm$ 0.0002	0.8090 $\pm$ 0.0004	0.5376 $\pm$ 0.0005	0.8132 $\pm$ 0.0070
6	Entropy	local logits	0.8399 $\pm$ 0.0004	0.8438 $\pm$ 0.0003	0.8001 $\pm$ 0.0004	0.5460 $\pm$ 0.0009	0.7121 $\pm$ 0.0003
7	RMD	DINOv2 feature	0.8363 $\pm$ 0.0001	0.8237 $\pm$ 0.0002	0.8253 $\pm$ 0.0001	0.4491 $\pm$ 0.0006	0.7474 $\pm$ 0.0002
8	ReAct	local logits/features	0.8327 $\pm$ 0.0004	0.8391 $\pm$ 0.0002	0.7856 $\pm$ 0.0004	0.5715 $\pm$ 0.0014	0.8139 $\pm$ 0.0053
9	MSP	local logits	0.8212 $\pm$ 0.0004	0.8351 $\pm$ 0.0003	0.7703 $\pm$ 0.0003	0.5895 $\pm$ 0.0004	0.6518 $\pm$ 0.0004
10	Euclidean MAF	DINOv2 feature	0.8163 $\pm$ 0.0001	0.8096 $\pm$ 0.0001	0.8092 $\pm$ 0.0002	0.4648 $\pm$ 0.0007	0.6018 $\pm$ 0.0002
11	KNN	DINOv2 feature	0.8161 $\pm$ 0.0002	0.8249 $\pm$ 0.0001	0.7858 $\pm$ 0.0003	0.5532 $\pm$ 0.0005	0.7433 $\pm$ 0.0009
12	MAF	DINOv2 feature	0.8135 $\pm$ 0.0002	0.7996 $\pm$ 0.0003	0.8115 $\pm$ 0.0003	0.4683 $\pm$ 0.0009	0.5840 $\pm$ 0.0011

5 考察

5.1 なぜ MAF は WILD DATA で有効だったのか

MAF の改善は, 分類ヘッドの出力ではなく, 凍結特徴空間におけるクラス幾何を利用した点に由来すると考えられる. DINOv2 の特徴空間では, ID 種のクラスタが比較的まとまり, OOD 種は近い ID クラスタの周辺または中間に配置される傾向がある. このような構造では, 入力が一つの ID クラスにどれだけ近いだけでなく, 全 ID クラスに対してどのような距離関係を持つかを見ることが重要である.

Mahalanobis 距離は, 特徴次元間分散と相関を考慮する. 野生動物画像では, 背景, 姿勢, 体の向き, 照明, 被写体のスケールなどにより特徴が大きく変動する. Euclidean 距離は全方向を等方に扱うため, ID 内で自然に変動しやすい方向と OOD らしさにつながる方向を区別しにくい. これに対して Mahalanobis 距離は, ID 特徴の共分散構造に基づいて距離を測るため, ID 分布に沿った変動と分布外方向のずれをある程度分離できる可能性がある.

さらに, MAF は最小距離を直接使わない. ある OOD 画像が一つの ID クラスに近く見える場合でも, 他の ID クラスとの距離分布全体が ID らしくない場合がある. $\text{conf}(x)$ は最近傍クラスへの集中を測るが, $\text{cons}(x)$ は正規化エントロピーの補数として分布の低エントロ

ピー性を測る. そのため, MAF は「一つの ID に近い」だけでなく, 「距離分布として ID らしい」ことを要求する. この設計が DINOv2 上で RMD や KNN を上回った一因である.

5.2 共有共分散が有効だった理由

要素実験では, 共有共分散 (tied covariance) の Final MAF が AUROC 0.8928 である一方, クラス別共分散 (class-wise covariance) の幾何融合は AUROC 0.7495 まで低下した. DINOv2 特徴は 768 次元であり, 各 ID 種の validation 画像からクラス別共分散の逆行列を安定に推定することは難しい. クラス別共分散は種ごとの有限サンプル分散に過適合しやすく, 各クラスへの距離のスケールも比較しにくくなる. 共有共分散は, 全 ID クラスで共通する異方性を安定に推定し, 全クラスへの距離を同じ計量で比較できる. 近接 OOD 検知では, クラス別の局所分散よりも, 特徴抽出器の特徴空間全体に共通する変動方向を安定に補正することが重要だったと解釈できる.

5.3 生特徴と L2 正規化特徴

生特徴 (raw feature) の Final MAF は AUROC 0.8928 であり, L2 正規化特徴 (L2 feature) 版は 0.8912 である. 差は小さいため, 「生特徴が常に優れる」とは

主張しない。ただし、WILD_DATA の DINOv2 特徴では、特徴ノルム (feature norm) や動径方向の情報に ID/OOD を分ける情報が少し残っていた可能性がある。L2 正規化は方向情報を強調する一方で、ノルムに含まれる有用な情報を消す可能性がある。ImageNet-scale 補助実験では Mahalanobis++ が AUROC で強いいため、特徴正規化の効果はデータセット、クラス数、特徴抽出器、目的指標に依存すると考えられる。

この点を確認するため、Mahalanobis++ も WILD_DATA 上で再評価した。具体的には、特徴を ℓ_2 正規化し、train/id 特徴からクラス平均を推定し、クラス中心化した train/id 特徴に対して共有経験共分散を推定し、最近傍クラスへの二乗 Mahalanobis 距離の負値を ID スコアとした。DINOv2 では AUROC 0.7707, FPR95 0.7376 となり、Final MAF を大きく下回った。これは Mahalanobis++ が一般に弱いことを意味しない。むしろ、WILD_DATA では OOD が ID クラスタ近傍に入り込むため、 ℓ_2 正規化により半径方向の差が失われ、さらに最近傍クラスへの最小距離だけでは ID クラス群に対する相対的な曖昧さを捉えにくいことを示唆する。MAF は距離ベクトル全体を分布化して評価するため、この Ultra-Near-OoD 条件に適していたと考えられる。

5.4 スコア構成成分の解釈

$\text{cons}(x)$ のみは AUROC 0.8921 と高いが、AUTC は 0.8089 で Final MAF より悪い。これは、一貫性成分 (consistency) 単独でも ID/OOD の順位付けには強いが、スコア分布が圧縮または飽和しやすく、閾値全体の挙動が悪化する可能性を示す。一方、 $\text{conf}(x)$ のみは AUROC 0.8854 であり、最近傍クラスへの集中だけでは十分ではない。幾何融合は、 $\text{conf}(x)$ と $\text{cons}(x)$ の両方を要求するため、AUROC と FPR95 のバランスが良い。

算術融合は AUROC 0.8905 で Final MAF より低い、AUTC は 0.7718 でわずかに良い。AUTC はスコアの単調変換やスケールに影響を受けやすく、AUROC のような順位のみを見る指標 (rank-only metric) ではない。したがって、主指標である AUROC と副次的な主要指標である FPR95 を重視すると、幾何融合を主設定とするのが妥当である。

5.5 α の決定に関する考察

主設定では $\alpha = 0.50$ を固定する。DINOv2 では、 $\text{cons}(x)$ のみ、すなわち $\alpha = 0$ でも AUROC 0.8921 であり、 $\alpha = 0.50$ との差は小さい。したがって、本研究の強さは「 α の細かな調整」だけに由来するものではない。より重要なのは、正則化 Mahalanobis 距離を距離 softmax 分布に変換し、その分布から $\text{conf}(x)$ と $\text{cons}(x)$ を構成する設計全体である。

一方、OOD ラベルを用いた oracle tuning を行うと性能がわずかに向上する可能性があるが、test OOD label を用いて α や τ を選ぶため実運用設定ではない。本稿では追加実験として ID validation のみを用いた α 選択も確認するが、主結果はあくまで固定 $\alpha = 0.50$ に基づく。今後は、データセットに依存しない固定値または ID-only selection 規則の妥当性を、AUROC だけでなく FPR95 と AUTC を含めて検証する必要がある。

5.6 補助実験から見える限界

ImageNet-1K/NINCO/SSB-hard 補助実験では、ViM や Mahalanobis++ が AUROC で MAF を上回った。これは、WILD_DATA で得られた結論を ImageNet-scale にそのまま拡張できないことを示す。ImageNet-1K ではクラス数が 1,000 であり、クラス平均 (class means)、共分散、距離 softmax の性質が 5 クラスの WILD_DATA とは大きく異なる。また、NINCO と SSB-hard は ImageNet ID クラスとの意味的距離を制御したベンチマークであり、WILD_DATA とはクラス構成、画像枚数、ドメインの一貫性が異なる。

この結果は MAF の限界を明確にする。MAF は Ultra-Near-OoD かつ ID 特徴が共有ガウス分布 (tied Gaussian) に近いという前提に依存する。WILD_DATA のように種数が少なく、DINOv2 特徴上で ID クラスタが比較的安定な場合には有効だが、ImageNet-scale ではロジットと残差部分空間 (residual subspace) を組み合わせる ViM や、 ℓ_2 正規化を重視する Mahalanobis++ が有利になる場合がある。したがって、MAF は汎用最強の OOD 検知器としてではなく、特定の特徴空間と Ultra-Near-OoD 条件で有効な学習後適用型スコアとして位置づける。

6 追加実験

本節では、WILD_DATA に対する追加解析を示す。主要な解析は DINOv2-ViT-B/14, seed 42, 固定 $\alpha = 0.50$, $\tau = 1.0$ の MAF スコアに基づく。OOD 種別解析のみ 3 seed 平均を用いる。これらの図は、平均指標だけでは見えにくい種別の難しさ、スコア分布、閾値依存の挙動、特徴空間の配置、画像レベルの成功例と失敗例を確認するために追加した。

6.1 OOD 種別解析

図 9 に OOD 種別の AUROC と FPR95 を示す。lion は AUROC 0.9700, FPR95 0.1603 で最も検出しやすい。一方、leopard は AUROC 0.7961, wildebeest は FPR95 0.8335 であり、これらは WILD_DATA における主要な失敗要因 (failure source) である。leopard は cheetah に、wildebeest は buffalo に視覚的に近く、Ultra-Near-OoD として難しい組み合わせであることが確認できる。

6.2 スコア分布と曲線

図 10 に MAF, Energy, RMD の生スコアヒストグラム (raw score histogram) を示す。MAF は ID と OOD の分布が Energy より分離し、閾値を置きやすい分布になっている。図 11 には ROC 曲線と precision-recall 曲線を示す。MAF は ROC 曲線でも高い TPR を保ちやすく、AUPR-IN/AUPR-OUT の両面でロジット系スコアより安定した挙動を示す。

6.3 特徴空間と共分散

図 12 に DINOv2 特徴の t-SNE 可視化と共分散固有値分布を示す。t-SNE では、ID 種の周辺または中間に OOD 種が現れる領域があり、近接 OOD が ID クラスタ近傍に埋め込まれることが確認できる。固有値分布ではクラス別共分散 (class-wise covariance) のばらつきが大きく、共有共分散 (tied covariance) を用いる設計が距離スケールの安定化に寄与することを示唆している。

表 6: 特徴入力後のスコア計算時間。特徴抽出器, 前処理, 後処理, disk I/O は含まない。

Method	Latency [ms/image]	Score cost
MAF	0.3935	$O(KD^2)$
KNN	0.2919	$O(ND)$

6.4 画像レベル解析

図 13 に ID/OOD 各種の代表画像を示す。図 14 には MAF が正しく OOD 判定した例と、OOD を ID として誤受理した失敗例 (failure case) を示す。失敗例では、leopard/cheetah や wildebeest/buffalo のように近い外観を持つ組み合わせが目立つ。

6.5 ID-only selection と計算量

図 15(a) に ID validation のみを用いた α 選択の確認結果を示す。固定 $\alpha = 0.50$ は極端な選択ではなく、ID-only な選択規則に対しても大きく外れない。表 6 には特徴入力後のスコア計算時間を示す。batch size 1 では MAF が 0.3935 ms/image, KNN が 0.2919 ms/image であり、どちらも特徴抽出器の推論に比べれば小さい。ただし、MAF は共分散逆行列を使うため $O(KD^2)$ 、総当たり KNN (brute-force KNN) は特徴バンク (feature bank) に対して $O(ND)$ のスコア計算を行う。

6.6 BioCLIP でのスコア分布

図 15(b) に BioCLIP 特徴でのスコア分布を示す。BioCLIP では MAF の AUROC は Energy を上回る一方、FPR95 では Energy がわずかに良い。スコアヒストグラムを見ると、MAF の ID/OOD 分離は改善しているが、高 TPR 領域で OOD スコアが残るため FPR95 では差が縮まる。この結果は、MAF の効果が特徴抽出器の特徴空間に依存することを示している。




図 9: OOD 種別の AUROC と FPR95. 棒の右側に 3 seed 平均値を示す. leopard と wildebeest は平均指標を押し下げる難例である.




図 10: MAF, Energy, RMD の生スコア分布 (raw score distribution). スコアは高いほど ID らしい方向にそろえている。






図 11: WILD_DATA における ROC 曲線と precision-recall 曲線.



(a) DINOv2 t-SNE



(b) Covariance eigenvalues

図 12: DINOv2 特徴空間の可視化と共分散固有値分布.




図 13: WILD_DATA の ID/OOD 代表画像.




図 14: MAF の成功例と失敗例. 各画像には最近傍 ID クラス, $\text{conf}(x)$, $\text{cons}(x)$, 最終スコアを併記している.





図 15: ID validation のみを用いた α 選択と BioCLIP 特徴におけるスコア分布.

7 結論

本稿では、野生動物画像の Ultra-Near-OoD 検知に対して、Mahalanobis Affinity Fusion (MAF) を提案した。MAF は、凍結 DINOv2 特徴上で各 ID クラスへの正則化 Mahalanobis 距離を計算し、距離ベクトルを softmax 分布として扱う。そのうえで、最近傍 ID クラスへの確信度 $\text{conf}(x)$ と距離分布全体の一貫性 $\text{cons}(x)$ を幾何融合する。WILD_DATA の 5 ID 種/5 OOD 種設定では、固定設定の MAF が AUROC 0.8928, FPR95 0.5128 を達成し、RMD, KNN, Energy, MaxLogit などの代表的 baseline を AUROC で上回った。要素実験では、共有共分散 (tied covariance), 生 DINOv2 特徴 (raw DINOv2 feature), 幾何融合が有効であり、クラス別共分散 (class-wise covariance) や Euclidean 距離では性能が大きく悪化することを確認した。

一方、ImageNet-1K/NINCO/SSB-hard 補助実験では、MAF は AUTC で低い値を示したものの、AUROC では ViM や Mahalanobis++ に劣った。したがって、本稿の結論は、MAF があらゆる OOD ベンチマークで最良であるというものではない。MAF は、ID 特徴分布が共有ガウス分布 (tied Gaussian) に近く、Ultra-Near-OoD が ID クラス周辺に現れる設定で有効な学習後適用型スコアである。以上より、MAF は、分類器の確信度だけでは棄却しにくい未知種に対して、特徴空間の Mahalanobis 幾何を利用する実用的な検知手段を与える。

参考文献

- [1] Dan Hendrycks and Kevin Gimpel. A baseline for detecting misclassified and out-of-distribution examples in neural networks. In *International Conference on Learning Representations*, 2017.
- [2] Weitang Liu, Xiaoyun Wang, John D. Owens, and Yixuan Li. Energy-based out-of-distribution detection. In *Advances in Neural Information Processing Systems*, volume 33, pages 21464–21475, 2020.
- [3] Dan Hendrycks, Steven Basart, Mantas Mazeika, Andy Zou, Joseph Kwon, Mohammadreza Mostajabi, Jacob Steinhardt, and Dawn Song. Scaling out-of-distribution detection for real-world settings. In *Proceedings of the 39th International Conference on Machine Learning*, volume 162 of *Proceedings of Machine Learning Research*, pages 8759–8773. PMLR, 2022.
- [4] Kimin Lee, Kibok Lee, Honglak Lee, and Jinwoo Shin. A simple unified framework for detecting out-of-distribution samples and adversarial attacks. In *Advances in Neural Information Processing Systems*, volume 31, 2018.
- [5] Jie Ren, Stanislav Fort, Jeremiah Zhe Liu, Abhijit Guha Roy, Shreyas Padhy, and Balaji Lakshminarayanan. A simple fix to mahalanobis distance for improving near-ood detection. *arXiv preprint arXiv:2106.09022*, 2021.
- [6] Yiyu Sun, Yifei Ming, Xiaojin Zhu, and Yixuan Li. Out-of-distribution detection with deep nearest neighbors. In *Proceedings of the 39th International Conference on Machine Learning*, volume 162 of *Proceedings of Machine Learning Research*, pages 20827–20840. PMLR, 2022.
- [7] Haoqi Wang, Zhizhong Li, Litong Feng, and Wayne Zhang. Vim: Out-of-distribution with virtual-logit matching. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 4921–4930, 2022.
- [8] Yiyu Sun, Chuan Guo, and Yixuan Li. React: Out-of-distribution detection with rectified activations.

- In *Advances in Neural Information Processing Systems*, volume 34, pages 144–157, 2021.
- [9] Yiyao Sun and Yixuan Li. Dice: Leveraging sparsification for out-of-distribution detection. In *European Conference on Computer Vision*, pages 691–708, 2022.
 - [10] Andrija Djuricic, Nebojsa Bozanic, Arjun Ashok, and Rosanne Liu. Extremely simple activation shaping for out-of-distribution detection. In *International Conference on Learning Representations*, 2023.
 - [11] Xixi Liu, Yaroslava Lochman, and Christopher Zach. Gen: Pushing the limits of softmax-based out-of-distribution detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 23946–23955, 2023.
 - [12] Kai Xu, Rongyu Chen, Gianni Franchi, and Angela Yao. Scaling for training time and post-hoc out-of-distribution detection enhancement. In *International Conference on Learning Representations*, 2024.
 - [13] Maximilian Müller and Matthias Hein. Mahalanobis++: Improving ood detection via feature normalization. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pages 45151–45184. PMLR, 2025.
 - [14] Galadrielle Humblot-Renaux, Sergio Escalera, and Thomas B. Moeslund. Beyond auroc & co. for evaluating out-of-distribution detection performance. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, 2023.
 - [15] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mahmoud Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jégou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. Dinov2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*, 2024.
 - [16] Olivier Ledoit and Michael Wolf. A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2):365–411, 2004.
 - [17] Julian Bitterwolf, Maximilian Müller, and Matthias Hein. In or out? fixing imagenet out-of-distribution detection evaluation. In *Proceedings of the 40th International Conference on Machine Learning*, volume 202 of *Proceedings of Machine Learning Research*, pages 2471–2506. PMLR, 2023.
 - [18] Sagar Vaze, Kai Han, Andrea Vedaldi, and Andrew Zisserman. Open-set recognition: A good closed-set classifier is all you need? In *International Conference on Learning Representations*, 2022.
 - [19] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning*, volume 139 of *Proceedings of Machine Learning Research*, pages 8748–8763. PMLR, 2021.
 - [20] Samuel Stevens, Jiaman Wu, Matthew J. Thompson, Elizabeth G. Campolongo, Chan Hee Song, David Edward Carlyn, Li Dong, Wasila M. Dahdul, Charles Stewart, Tanya Berger-Wolf, Wei-Lun Chao, and Yu Su. Bioclip: A vision foundation model for the tree of life. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.

A 全実験結果

本付録には、本文で要約した実験結果の全表をまとめる。AUROC, AUPR-IN, AUPR-OUT は高いほど良く、FPR95 と AUTC は低いほど良い。いずれも 3 seed 平均 $\pm$ 標準偏差である。WILD_DATA の固定 MAF は $\alpha = 0.50$, $\tau = 1.0$, 生特徴 (raw feature), 共有共分散 (tied covariance), Ledoit-Wolf 推定であり, test OOD label で選択した値ではない。一方, ImageNet-scale 補助実験の一部行は oracle または tuned 設定を含むため、本文と同じく補助結果として扱う。

表 7: WILD_DATA における先行研究および baseline 比較の全結果. FPR95 と AUTC は低いほど良い。

Rank	Method	Variant	Venue	Authors	AUROC	AUPR-IN	AUPR-OUT	FPR95	AUTC
1	MAF	MAF mah.t raw	This work	This paper	0.8928 $\pm$ 0.0000	0.9002 $\pm$ 0.0000	0.8793 $\pm$ 0.0000	0.5121 $\pm$ 0.0008	0.7731 $\pm$ 0.0003
2	RMD	RMD raw, val, squared	UDL@NeurIPS 2021	Ren et al.	0.8705 $\pm$ 0.0001	0.8720 $\pm$ 0.0001	0.8548 $\pm$ 0.0001	0.5507 $\pm$ 0.0005	0.8271 $\pm$ 0.0002
3	KNN	KNN raw	ICML 2022	Sun et al.	0.8523 $\pm$ 0.0000	0.8404 $\pm$ 0.0000	0.8529 $\pm$ 0.0000	0.5366 $\pm$ 0.0000	0.7826 $\pm$ 0.0000
4	ASH-P	ASH-P	ICLR 2023	Djurisic et al.	0.8398 $\pm$ 0.0311	0.8279 $\pm$ 0.0325	0.8428 $\pm$ 0.0319	0.5835 $\pm$ 0.0548	0.8698 $\pm$ 0.0141
5	ReAct	ReAct	NeurIPS 2021	Sun et al.	0.8379 $\pm$ 0.0304	0.8268 $\pm$ 0.0386	0.8397 $\pm$ 0.0269	0.5743 $\pm$ 0.0443	0.8956 $\pm$ 0.0171
6	ASH-S	ASH-S	ICLR 2023	Djurisic et al.	0.8357 $\pm$ 0.0310	0.8236 $\pm$ 0.0319	0.8373 $\pm$ 0.0318	0.6081 $\pm$ 0.0549	0.8746 $\pm$ 0.0122
7	SCALE	SCALE	ICLR 2024	Xu et al.	0.8356 $\pm$ 0.0308	0.8237 $\pm$ 0.0313	0.8367 $\pm$ 0.0313	0.6090 $\pm$ 0.0532	0.8890 $\pm$ 0.0233
8	MaxLogit	MaxLogit, Linear(768 $\rightarrow$ 5)	ICML 2022	Hendrycks et al.	0.8335 $\pm$ 0.0060	0.8578 $\pm$ 0.0080	0.7769 $\pm$ 0.0101	0.8040 $\pm$ 0.0141	0.7745 $\pm$ 0.0050
9	Energy	Energy, Linear(768 $\rightarrow$ 5)	NeurIPS 2020	Liu et al.	0.8330 $\pm$ 0.0061	0.8575 $\pm$ 0.0080	0.7768 $\pm$ 0.0107	0.8025 $\pm$ 0.0174	0.7706 $\pm$ 0.0055
10	Entropy	Entropy, Linear(768 $\rightarrow$ 5)	ICLR 2017	Hendrycks and Gimpel	0.8314 $\pm$ 0.0025	0.8537 $\pm$ 0.0026	0.7784 $\pm$ 0.0045	0.7952 $\pm$ 0.0081	0.8055 $\pm$ 0.0159
11	MSP	MSP, Linear(768 $\rightarrow$ 5)	ICLR 2017	Hendrycks and Gimpel	0.8307 $\pm$ 0.0023	0.8532 $\pm$ 0.0024	0.7761 $\pm$ 0.0045	0.7894 $\pm$ 0.0069	0.8340 $\pm$ 0.0118
12	ViM	diagnostic	CVPR 2022	Wang et al.	0.8305 $\pm$ 0.0191	0.8282 $\pm$ 0.0304	0.8258 $\pm$ 0.0152	0.6151 $\pm$ 0.0199	0.9646 $\pm$ 0.0606
13	Mah-MinDist	Mah-MinDist euc raw	NeurIPS 2018	Lee et al.	0.8233 $\pm$ 0.0000	0.8520 $\pm$ 0.0000	0.7884 $\pm$ 0.0000	0.7445 $\pm$ 0.0000	0.7984 $\pm$ 0.0000
14	GEN	GEN	CVPR 2023	Liu et al.	0.7908 $\pm$ 0.0135	0.7946 $\pm$ 0.0150	0.7455 $\pm$ 0.0109	0.8273 $\pm$ 0.0070	0.6845 $\pm$ 0.0316
15	Mahalanobis++	L2 MinDist	ICML 2025	Müller and Hein	0.7707 $\pm$ 0.0000	0.7380 $\pm$ 0.0000	0.7594 $\pm$ 0.0000	0.7376 $\pm$ 0.0000	0.9060 $\pm$ 0.0000
16	DICE	DICE	ECCV 2022	Sun and Li	0.7664 $\pm$ 0.0156	0.7733 $\pm$ 0.0058	0.7046 $\pm$ 0.0127	0.8769 $\pm$ 0.0153	0.8242 $\pm$ 0.0159
17	ASH-B	ASH-B	ICLR 2023	Djurisic et al.	0.7538 $\pm$ 0.0218	0.7275 $\pm$ 0.0205	0.7480 $\pm$ 0.0200	0.7575 $\pm$ 0.0225	0.9222 $\pm$ 0.0136
18	NCI	NCI	CVPR 2025	Liu and Qin	0.6930 $\pm$ 0.0150	0.7014 $\pm$ 0.0131	0.6494 $\pm$ 0.0106	0.8856 $\pm$ 0.0056	0.9196 $\pm$ 0.0031

表 8: DINOv2-ViT-B/14 における WILD_DATA 要素実験 (ablation) の全結果. 固定 MAF($\alpha = 0.50$) と確認用設定 (oracle check) を区別して読む必要がある。

Rank	Group	Variant	Method	AUROC	AUPR-IN	AUPR-OUT	FPR95	AUTC
1	MAF (Ours)	MAF mah.t raw	MAF	0.8928 $\pm$ 0.0000	0.9002 $\pm$ 0.0000	0.8793 $\pm$ 0.0000	0.5121 $\pm$ 0.0008	0.7731 $\pm$ 0.0003
2	Component / fusion ablation	geometric fusion alpha=0.50 (tied LW)	geometric fusion alpha=0.50	0.8928 $\pm$ 0.0000	0.9002 $\pm$ 0.0000	0.8793 $\pm$ 0.0000	0.5128 $\pm$ 0.0002	0.7734 $\pm$ 0.0000
3	Component / fusion ablation	conf(x) only (tied LW)	conf(x) only	0.8921 $\pm$ 0.0000	0.8995 $\pm$ 0.0000	0.8788 $\pm$ 0.0000	0.5171 $\pm$ 0.0004	0.8089 $\pm$ 0.0000
4	Component / fusion ablation	geometric fusion alpha=0.50 (tied emp.)	geometric fusion alpha=0.50	0.8917 $\pm$ 0.0000	0.8982 $\pm$ 0.0000	0.8785 $\pm$ 0.0000	0.5185 $\pm$ 0.0001	0.7768 $\pm$ 0.0000
5	Feature normalization ablation	MAF mah.t L2	MAF	0.8912 $\pm$ 0.0000	0.8996 $\pm$ 0.0000	0.8765 $\pm$ 0.0000	0.5223 $\pm$ 0.0003	0.7885 $\pm$ 0.0001
6	Component / fusion ablation	arithmetic fusion alpha=0.50 (tied LW)	arithmetic fusion alpha=0.50	0.8905 $\pm$ 0.0000	0.8984 $\pm$ 0.0000	0.8744 $\pm$ 0.0000	0.5307 $\pm$ 0.0004	0.7718 $\pm$ 0.0000
7	Component / fusion ablation	conf(x) only (tied LW)	conf(x) only	0.8854 $\pm$ 0.0000	0.8940 $\pm$ 0.0000	0.8670 $\pm$ 0.0000	0.5622 $\pm$ 0.0002	0.7401 $\pm$ 0.0000
8	Distance-score ablation	Mah-LSE euc raw	Mah-LSE	0.8231 $\pm$ 0.0000	0.8514 $\pm$ 0.0000	0.7898 $\pm$ 0.0000	0.7342 $\pm$ 0.0002	0.7962 $\pm$ 0.0000
9	Distance-score ablation	Mah-LSE mah.c raw	Mah-LSE	0.8174 $\pm$ 0.0000	0.7974 $\pm$ 0.0000	0.8126 $\pm$ 0.0000	0.6283 $\pm$ 0.0000	0.8378 $\pm$ 0.0000
10	Distance metric ablation	MAF euclidean L2	MAF	0.8120 $\pm$ 0.0000	0.8596 $\pm$ 0.0000	0.7341 $\pm$ 0.0000	0.8592 $\pm$ 0.0001	0.7271 $\pm$ 0.0000
11	Distance metric ablation	MAF euclidean raw	MAF	0.8096 $\pm$ 0.0000	0.8570 $\pm$ 0.0000	0.7319 $\pm$ 0.0000	0.8576 $\pm$ 0.0002	0.7184 $\pm$ 0.0000
12	Covariance ablation	MAF mah.c L2	MAF	0.7742 $\pm$ 0.0000	0.7986 $\pm$ 0.0000	0.7289 $\pm$ 0.0000	0.8247 $\pm$ 0.0002	0.7298 $\pm$ 0.0000
13	Covariance ablation	MAF mah.c raw	MAF	0.7691 $\pm$ 0.0000	0.7928 $\pm$ 0.0000	0.7219 $\pm$ 0.0000	0.8335 $\pm$ 0.0001	0.7308 $\pm$ 0.0000
14	Distance-score ablation	Mah-LSE mah.t raw	Mah-LSE	0.7660 $\pm$ 0.0000	0.7150 $\pm$ 0.0000	0.7614 $\pm$ 0.0000	0.7300 $\pm$ 0.0001	0.8797 $\pm$ 0.0000
15	Component / fusion ablation	geometric fusion alpha=0.50 (class-wise emp.)	geometric fusion alpha=0.50	0.7598 $\pm$ 0.0000	0.7836 $\pm$ 0.0000	0.7048 $\pm$ 0.0001	0.8522 $\pm$ 0.0004	0.9187 $\pm$ 0.0001
16	Component / fusion ablation	geometric fusion alpha=0.50 (class-wise LW)	geometric fusion alpha=0.50	0.7495 $\pm$ 0.0000	0.7692 $\pm$ 0.0000	0.6989 $\pm$ 0.0000	0.8574 $\pm$ 0.0003	0.9162 $\pm$ 0.0000
17	Distance-score ablation	Mah-LSE euc L2	Mah-LSE	0.6724 $\pm$ 0.0000	0.6440 $\pm$ 0.0000	0.6592 $\pm$ 0.0000	0.8471 $\pm$ 0.0001	0.8998 $\pm$ 0.0000

A.1 WILD_DATA: 特徴抽出器別スコア variant 全結果

表 9–表 12 は、中間報告で整理した各特徴抽出器の OOD スコア variant をそのまま付録に移したものである。これらは WILD_DATA 上の結果であり、OOD validation split は MAF の固定設定に使用していない。

表 9: WILD_DATA における DINOv2-ViT-B/14 のスコア variant 全結果。

Variant	Cov.	Est.	AUROC	AUPR-IN	AUPR-OUT	FPR95	AUTC
MAF (幾何融合) $\alpha = 0.50$	tied	LW	0.8928 $\pm$ 0.0000	0.9002 $\pm$ 0.0000	0.8793 $\pm$ 0.0000	0.5128 $\pm$ 0.0002	0.7734 $\pm$ 0.0000
MAF (幾何融合) $\alpha = 0.75$	tied	LW	0.8922 $\pm$ 0.0000	0.8994 $\pm$ 0.0000	0.8784 $\pm$ 0.0000	0.5157 $\pm$ 0.0001	0.7641 $\pm$ 0.0000
cons(x) のみ	tied	LW	0.8921 $\pm$ 0.0000	0.8995 $\pm$ 0.0000	0.8788 $\pm$ 0.0000	0.5171 $\pm$ 0.0004	0.8089 $\pm$ 0.0000
MAF (幾何融合) $\alpha = 0.75$	tied	empirical	0.8912 $\pm$ 0.0000	0.8976 $\pm$ 0.0000	0.8779 $\pm$ 0.0000	0.5184 $\pm$ 0.0001	0.7686 $\pm$ 0.0000
算術平均 $\alpha = 0.50$	tied	LW	0.8905 $\pm$ 0.0000	0.8984 $\pm$ 0.0000	0.8744 $\pm$ 0.0000	0.5307 $\pm$ 0.0004	0.7718 $\pm$ 0.0000
算術融合 $\alpha = 0.75$	tied	LW	0.8880 $\pm$ 0.0000	0.8963 $\pm$ 0.0000	0.8707 $\pm$ 0.0000	0.5499 $\pm$ 0.0004	0.7553 $\pm$ 0.0000
conf(x) のみ	tied	LW	0.8854 $\pm$ 0.0000	0.8940 $\pm$ 0.0000	0.8670 $\pm$ 0.0000	0.5622 $\pm$ 0.0002	0.7401 $\pm$ 0.0000
最近傍 Mahalanobis 距離	class-wise	LW	0.8186 $\pm$ 0.0000	0.8013 $\pm$ 0.0000	0.8131 $\pm$ 0.0000	0.6288 $\pm$ 0.0001	0.8376 $\pm$ 0.0000
Euclidean 融合 $\alpha = 0.50$	–	–	0.8032 $\pm$ 0.0000	0.8467 $\pm$ 0.0000	0.7290 $\pm$ 0.0000	0.8489 $\pm$ 0.0004	0.8199 $\pm$ 0.0001
Euclidean 融合 $\alpha = 0.75$	–	–	0.8031 $\pm$ 0.0000	0.8465 $\pm$ 0.0000	0.7296 $\pm$ 0.0000	0.8512 $\pm$ 0.0003	0.8327 $\pm$ 0.0001
最近傍 Mahalanobis 距離	tied	LW	0.7761 $\pm$ 0.0000	0.7315 $\pm$ 0.0000	0.7695 $\pm$ 0.0000	0.7192 $\pm$ 0.0001	0.8741 $\pm$ 0.0000
最近傍 Mahalanobis 距離	tied	empirical	0.7756 $\pm$ 0.0000	0.7305 $\pm$ 0.0000	0.7690 $\pm$ 0.0000	0.7203 $\pm$ 0.0001	0.8759 $\pm$ 0.0000
MAF (幾何融合) $\alpha = 0.75$	class-wise	empirical	0.7596 $\pm$ 0.0000	0.7815 $\pm$ 0.0000	0.7048 $\pm$ 0.0001	0.8538 $\pm$ 0.0002	0.9228 $\pm$ 0.0001
MAF (幾何融合) $\alpha = 0.75$	class-wise	LW	0.7494 $\pm$ 0.0000	0.7687 $\pm$ 0.0000	0.6990 $\pm$ 0.0000	0.8606 $\pm$ 0.0004	0.9200 $\pm$ 0.0000

表 10: WILD_DATA における BioCLIP のスコア variant 全結果。

Variant	Cov.	Est.	AUROC	AUPR-IN	AUPR-OUT	FPR95	AUTC
MAF (幾何融合) $\alpha = 0.75$	tied	LW	0.8031 $\pm$ 0.0000	0.8161 $\pm$ 0.0000	0.7724 $\pm$ 0.0000	0.7327 $\pm$ 0.0001	0.8490 $\pm$ 0.0000
MAF (幾何融合) $\alpha = 0.75$	tied	empirical	0.8028 $\pm$ 0.0000	0.8154 $\pm$ 0.0000	0.7723 $\pm$ 0.0000	0.7325 $\pm$ 0.0003	0.8505 $\pm$ 0.0000
MAF (幾何融合) $\alpha = 0.50$	tied	LW	0.8025 $\pm$ 0.0000	0.8154 $\pm$ 0.0000	0.7728 $\pm$ 0.0000	0.7280 $\pm$ 0.0001	0.8570 $\pm$ 0.0000
cons(x) のみ	tied	LW	0.8005 $\pm$ 0.0000	0.8134 $\pm$ 0.0000	0.7720 $\pm$ 0.0000	0.7259 $\pm$ 0.0002	0.8845 $\pm$ 0.0000
算術平均 $\alpha = 0.50$	tied	LW	0.8004 $\pm$ 0.0000	0.8150 $\pm$ 0.0000	0.7654 $\pm$ 0.0000	0.7544 $\pm$ 0.0003	0.8553 $\pm$ 0.0000
算術融合 $\alpha = 0.75$	tied	LW	0.7978 $\pm$ 0.0000	0.8132 $\pm$ 0.0000	0.7612 $\pm$ 0.0000	0.7701 $\pm$ 0.0002	0.8443 $\pm$ 0.0000
conf(x) のみ	tied	LW	0.7954 $\pm$ 0.0000	0.8113 $\pm$ 0.0000	0.7575 $\pm$ 0.0001	0.7748 $\pm$ 0.0004	0.8350 $\pm$ 0.0000
Euclidean 融合 $\alpha = 0.50$	–	–	0.7710 $\pm$ 0.0000	0.7964 $\pm$ 0.0000	0.7145 $\pm$ 0.0000	0.8347 $\pm$ 0.0001	0.8253 $\pm$ 0.0000
Euclidean 融合 $\alpha = 0.75$	–	–	0.7684 $\pm$ 0.0000	0.7944 $\pm$ 0.0000	0.7125 $\pm$ 0.0000	0.8332 $\pm$ 0.0001	0.8221 $\pm$ 0.0000
最近傍 Mahalanobis 距離	class-wise	LW	0.7560 $\pm$ 0.0000	0.7829 $\pm$ 0.0000	0.7138 $\pm$ 0.0000	0.8367 $\pm$ 0.0002	0.8831 $\pm$ 0.0000
MAF (幾何融合) $\alpha = 0.75$	class-wise	empirical	0.7545 $\pm$ 0.0000	0.7926 $\pm$ 0.0000	0.7072 $\pm$ 0.0001	0.8448 $\pm$ 0.0008	0.8500 $\pm$ 0.0001
MAF (幾何融合) $\alpha = 0.75$	class-wise	LW	0.7446 $\pm$ 0.0000	0.7817 $\pm$ 0.0000	0.6981 $\pm$ 0.0000	0.8395 $\pm$ 0.0004	0.8633 $\pm$ 0.0001
最近傍 Mahalanobis 距離	tied	LW	0.6758 $\pm$ 0.0000	0.7058 $\pm$ 0.0000	0.6405 $\pm$ 0.0000	0.8896 $\pm$ 0.0001	0.9272 $\pm$ 0.0000
最近傍 Mahalanobis 距離	tied	empirical	0.6746 $\pm$ 0.0000	0.7043 $\pm$ 0.0000	0.6398 $\pm$ 0.0000	0.8917 $\pm$ 0.0000	0.9270 $\pm$ 0.0000

表 11: WILD_DATA における ImageNet-ViT のスコア variant 全結果。

Variant	Cov.	Est.	AUROC	AUPR-IN	AUPR-OUT	FPR95	AUTC
算術平均 $\alpha = 0.50$	tied	LW	0.8463 $\pm$ 0.0000	0.8647 $\pm$ 0.0000	0.8142 $\pm$ 0.0001	0.6788 $\pm$ 0.0006	0.8244 $\pm$ 0.0000
算術融合 $\alpha = 0.75$	tied	LW	0.8463 $\pm$ 0.0000	0.8652 $\pm$ 0.0000	0.8129 $\pm$ 0.0001	0.6884 $\pm$ 0.0005	0.8079 $\pm$ 0.0000
conf(x) のみ	tied	LW	0.8457 $\pm$ 0.0000	0.8651 $\pm$ 0.0000	0.8115 $\pm$ 0.0001	0.6928 $\pm$ 0.0002	0.7926 $\pm$ 0.0000
MAF (幾何融合) $\alpha = 0.75$	tied	LW	0.8453 $\pm$ 0.0000	0.8633 $\pm$ 0.0000	0.8145 $\pm$ 0.0000	0.6739 $\pm$ 0.0003	0.8152 $\pm$ 0.0002
MAF (幾何融合) $\alpha = 0.75$	tied	empirical	0.8448 $\pm$ 0.0000	0.8628 $\pm$ 0.0000	0.8124 $\pm$ 0.0000	0.6727 $\pm$ 0.0004	0.8191 $\pm$ 0.0002
MAF (幾何融合) $\alpha = 0.50$	tied	LW	0.8426 $\pm$ 0.0000	0.8606 $\pm$ 0.0000	0.8126 $\pm$ 0.0000	0.6777 $\pm$ 0.0016	0.8260 $\pm$ 0.0001
cons(x) のみ	tied	LW	0.8393 $\pm$ 0.0000	0.8570 $\pm$ 0.0000	0.8103 $\pm$ 0.0000	0.6780 $\pm$ 0.0003	0.8616 $\pm$ 0.0000
Euclidean 融合 $\alpha = 0.50$	–	–	0.7804 $\pm$ 0.0000	0.8036 $\pm$ 0.0000	0.7486 $\pm$ 0.0000	0.7827 $\pm$ 0.0002	0.7572 $\pm$ 0.0000
Euclidean 融合 $\alpha = 0.75$	–	–	0.7780 $\pm$ 0.0000	0.8025 $\pm$ 0.0000	0.7438 $\pm$ 0.0000	0.7927 $\pm$ 0.0005	0.7684 $\pm$ 0.0000
MAF (幾何融合) $\alpha = 0.75$	class-wise	empirical	0.7453 $\pm$ 0.0000	0.7919 $\pm$ 0.0000	0.6876 $\pm$ 0.0000	0.8676 $\pm$ 0.0002	0.9160 $\pm$ 0.0001
MAF (幾何融合) $\alpha = 0.75$	class-wise	LW	0.7421 $\pm$ 0.0000	0.7941 $\pm$ 0.0000	0.6794 $\pm$ 0.0000	0.8765 $\pm$ 0.0002	0.9094 $\pm$ 0.0000
最近傍 Mahalanobis 距離	class-wise	LW	0.7348 $\pm$ 0.0000	0.7657 $\pm$ 0.0000	0.6942 $\pm$ 0.0000	0.8391 $\pm$ 0.0000	0.8918 $\pm$ 0.0000
最近傍 Mahalanobis 距離	tied	empirical	0.7245 $\pm$ 0.0000	0.7564 $\pm$ 0.0000	0.6851 $\pm$ 0.0000	0.8501 $\pm$ 0.0000	0.8987 $\pm$ 0.0000
最近傍 Mahalanobis 距離	tied	LW	0.7237 $\pm$ 0.0000	0.7566 $\pm$ 0.0000	0.6838 $\pm$ 0.0000	0.8522 $\pm$ 0.0000	0.8982 $\pm$ 0.0000

表 12: WILD_DATA における OpenAI CLIP-B/16 のスコア variant 全結果。

Variant	Cov.	Est.	AUROC	AUPR-IN	AUPR-OUT	FPR95	AUTC
MAF (幾何融合) $\alpha = 0.75$	tied	empirical	0.8303 $\pm$ 0.0000	0.8384 $\pm$ 0.0000	0.8064 $\pm$ 0.0000	0.6821 $\pm$ 0.0002	0.8240 $\pm$ 0.0001
MAF (幾何融合) $\alpha = 0.75$	tied	LW	0.8301 $\pm$ 0.0000	0.8382 $\pm$ 0.0000	0.8063 $\pm$ 0.0000	0.6850 $\pm$ 0.0003	0.8217 $\pm$ 0.0001
MAF (幾何融合) $\alpha = 0.50$	tied	LW	0.8291 $\pm$ 0.0000	0.8364 $\pm$ 0.0000	0.8062 $\pm$ 0.0000	0.6824 $\pm$ 0.0001	0.8274 $\pm$ 0.0000
算術平均 $\alpha = 0.50$	tied	LW	0.8283 $\pm$ 0.0000	0.8379 $\pm$ 0.0000	0.8026 $\pm$ 0.0000	0.6933 $\pm$ 0.0003	0.8238 $\pm$ 0.0000
cons(x) のみ	tied	LW	0.8263 $\pm$ 0.0000	0.8328 $\pm$ 0.0000	0.8047 $\pm$ 0.0000	0.6845 $\pm$ 0.0002	0.8537 $\pm$ 0.0000
算術融合 $\alpha = 0.75$	tied	LW	0.8262 $\pm$ 0.0000	0.8369 $\pm$ 0.0000	0.7990 $\pm$ 0.0000	0.7057 $\pm$ 0.0002	0.8128 $\pm$ 0.0000
conf(x) のみ	tied	LW	0.8241 $\pm$ 0.0000	0.8357 $\pm$ 0.0000	0.7956 $\pm$ 0.0000	0.7151 $\pm$ 0.0003	0.8036 $\pm$ 0.0000
最近傍 Mahalanobis 距離	class-wise	LW	0.7789 $\pm$ 0.0000	0.7669 $\pm$ 0.0000	0.7567 $\pm$ 0.0000	0.7485 $\pm$ 0.0001	0.9032 $\pm$ 0.0000
Euclidean 融合 $\alpha = 0.75$	–	–	0.7588 $\pm$ 0.0000	0.7806 $\pm$ 0.0000	0.7190 $\pm$ 0.0000	0.8021 $\pm$ 0.0002	0.8319 $\pm$ 0.0000
Euclidean 融合 $\alpha = 0.50$	–	–	0.7553 $\pm$ 0.0000	0.7770 $\pm$ 0.0000	0.7184 $\pm$ 0.0000	0.7967 $\pm$ 0.0003	0.8322 $\pm$ 0.0000
MAF (幾何融合) $\alpha = 0.75$	class-wise	empirical	0.7506 $\pm$ 0.0000	0.7857 $\pm$ 0.0000	0.6892 $\pm$ 0.0000	0.8784 $\pm$ 0.0004	0.8957 $\pm$ 0.0002
MAF (幾何融合) $\alpha = 0.75$	class-wise	LW	0.7463 $\pm$ 0.0000	0.7676 $\pm$ 0.0000	0.6977 $\pm$ 0.0000	0.8516 $\pm$ 0.0003	0.8742 $\pm$ 0.0001
最近傍 Mahalanobis 距離	tied	empirical	0.6761 $\pm$ 0.0000	0.6673 $\pm$ 0.0000	0.6456 $\pm$ 0.0000	0.8771 $\pm$ 0.0002	0.9515 $\pm$ 0.0000
最近傍 Mahalanobis 距離	tied	LW	0.6753 $\pm$ 0.0000	0.6680 $\pm$ 0.0000	0.6438 $\pm$ 0.0000	0.8826 $\pm$ 0.0001	0.9524 $\pm$ 0.0000

A.2 ImageNet-scale 補助実験: NINCO/SSB-hard/ALL-OOD 全結果

以下の表は, ImageNet-1K を ID, NINCO および SSB-hard を近接 OOD とした補助実験の CSV を全行掲載したものである. ALL-OOD 平均は NINCO と SSB-hard の dataset 単純平均であり, 画像枚数で重み付けしていない.

表 13: ImageNet-scale 補助実験の全結果: ALL-OOD 平均.

Rank	Display	Impl.	Backbone	AUROC	AUPR-IN	AUPR-OUT	FPR95-test	FPR95-val	AUTC
1	ViM	ViM	dinov2_vitb14_lc	0.8828 ± 0.0002	0.8758 ± 0.0001	0.8727 ± 0.0002	0.4096 ± 0.0004	0.4118 ± 0.0022	0.7781 ± 0.0001
2	Mahalanobis++	L2 MAF	dinov2_vitb14	0.8654 ± 0.0001	0.8674 ± 0.0001	0.8445 ± 0.0003	0.4602 ± 0.0002	0.4593 ± 0.0004	0.7967 ± 0.0019
3	MaxLogit	MaxLogit	dinov2_vitb14_lc	0.8518 ± 0.0003	0.8550 ± 0.0002	0.8109 ± 0.0003	0.5323 ± 0.0007	0.5342 ± 0.0052	0.8081 ± 0.0063
4	GEN	GEN	dinov2_vitb14_lc	0.8512 ± 0.0003	0.8536 ± 0.0002	0.8086 ± 0.0003	0.5379 ± 0.0010	0.5349 ± 0.0089	0.7245 ± 0.0026
5	Energy	Energy	dinov2_vitb14_lc	0.8498 ± 0.0003	0.8535 ± 0.0002	0.8090 ± 0.0004	0.5376 ± 0.0005	0.5348 ± 0.0059	0.8132 ± 0.0070
6	Entropy	Entropy	dinov2_vitb14_lc	0.8399 ± 0.0004	0.8438 ± 0.0003	0.8001 ± 0.0004	0.5460 ± 0.0009	0.5490 ± 0.0092	0.7121 ± 0.0003
7	RMD	RMD	dinov2_vitb14	0.8363 ± 0.0001	0.8237 ± 0.0002	0.8253 ± 0.0001	0.4491 ± 0.0006	0.4507 ± 0.0063	0.7474 ± 0.0002
8	ReAct	ReAct	dinov2_vitb14_lc	0.8327 ± 0.0004	0.8391 ± 0.0002	0.7856 ± 0.0004	0.5715 ± 0.0014	0.5645 ± 0.0116	0.8139 ± 0.0053
9	MSP	MSP	dinov2_vitb14_lc	0.8212 ± 0.0004	0.8351 ± 0.0003	0.7703 ± 0.0003	0.5895 ± 0.0004	0.5917 ± 0.0062	0.6518 ± 0.0004
10	Euclidean MAF	Euclidean MAF	dinov2_vitb14	0.8163 ± 0.0001	0.8096 ± 0.0001	0.8092 ± 0.0002	0.4648 ± 0.0007	0.4654 ± 0.0057	0.6018 ± 0.0002
11	KNN	KNN	dinov2_vitb14	0.8161 ± 0.0002	0.8249 ± 0.0001	0.7858 ± 0.0003	0.5532 ± 0.0005	0.5572 ± 0.0054	0.7433 ± 0.0009
12	MAF	MAF	dinov2_vitb14	0.8135 ± 0.0002	0.7996 ± 0.0003	0.8115 ± 0.0003	0.4683 ± 0.0009	0.4685 ± 0.0054	0.5840 ± 0.0011
13	ASH-S	ASH-S	dinov2_vitb14_lc	0.7532 ± 0.0003	0.7832 ± 0.0002	0.7044 ± 0.0006	0.6748 ± 0.0007	0.6774 ± 0.0070	0.9219 ± 0.0019
14	ASH-P	ASH-P	dinov2_vitb14_lc	0.7207 ± 0.0007	0.7695 ± 0.0004	0.6236 ± 0.0009	0.7638 ± 0.0006	0.7594 ± 0.0084	0.9426 ± 0.0001
15	DICE	DICE	dinov2_vitb14_lc	0.6466 ± 0.0000	0.6811 ± 0.0001	0.6274 ± 0.0001	0.7045 ± 0.0004	0.7083 ± 0.0027	0.8795 ± 0.0003
16	NCI	NCI	dinov2_vitb14_lc	0.3743 ± 0.0002	0.5348 ± 0.0001	0.3248 ± 0.0001	0.9778 ± 0.0001	0.9774 ± 0.0010	1.0705 ± 0.0001
17	SCALE	SCALE	dinov2_vitb14_lc	0.3343 ± 0.0002	0.5201 ± 0.0003	0.3319 ± 0.0001	0.9640 ± 0.0001	0.9632 ± 0.0004	1.0848 ± 0.0004
18	ASH-B	ASH-B	dinov2_vitb14_lc	0.3158 ± 0.0002	0.5108 ± 0.0003	0.3216 ± 0.0001	0.9701 ± 0.0002	0.9712 ± 0.0011	1.0990 ± 0.0007

表 14: ImageNet-scale 補助実験の全結果: NINCO.

Rank	Display	Impl.	Backbone	AUROC	AUPR-IN	AUPR-OUT	FPR95-test	FPR95-val	AUTC
1	ViM	ViM	dinov2_vitb14_lc	0.9572 ± 0.0001	0.9829 ± 0.0000	0.9173 ± 0.0001	0.2007 ± 0.0005	0.2026 ± 0.0017	0.6719 ± 0.0001
2	Mahalanobis++	L2 MAF	dinov2_vitb14	0.9438 ± 0.0001	0.9775 ± 0.0000	0.8899 ± 0.0004	0.2494 ± 0.0007	0.2471 ± 0.0035	0.7023 ± 0.0002
3	GEN	GEN	dinov2_vitb14_lc	0.9384 ± 0.0002	0.9762 ± 0.0001	0.8631 ± 0.0002	0.2959 ± 0.0011	0.2928 ± 0.0092	0.6234 ± 0.0036
4	RMD	RMD	dinov2_vitb14	0.9360 ± 0.0001	0.9720 ± 0.0000	0.8680 ± 0.0001	0.2356 ± 0.0006	0.2371 ± 0.0064	0.6605 ± 0.0004
5	MaxLogit	MaxLogit	dinov2_vitb14_lc	0.9350 ± 0.0002	0.9746 ± 0.0001	0.8610 ± 0.0002	0.2973 ± 0.0008	0.2995 ± 0.0052	0.7380 ± 0.0085
6	Energy	Energy	dinov2_vitb14_lc	0.9335 ± 0.0002	0.9739 ± 0.0001	0.8599 ± 0.0003	0.3020 ± 0.0003	0.3000 ± 0.0044	0.7510 ± 0.0093
7	Entropy	Entropy	dinov2_vitb14_lc	0.9284 ± 0.0002	0.9712 ± 0.0001	0.8521 ± 0.0003	0.3187 ± 0.0008	0.3219 ± 0.0089	0.5727 ± 0.0003
8	MAF	MAF	dinov2_vitb14	0.9264 ± 0.0001	0.9662 ± 0.0000	0.8686 ± 0.0003	0.2474 ± 0.0009	0.2476 ± 0.0060	0.3896 ± 0.0004
9	ReAct	ReAct	dinov2_vitb14_lc	0.9259 ± 0.0002	0.9708 ± 0.0001	0.8464 ± 0.0003	0.3175 ± 0.0016	0.3114 ± 0.0108	0.7453 ± 0.0072
10	Euclidean MAF	Euclidean MAF	dinov2_vitb14	0.9233 ± 0.0001	0.9651 ± 0.0000	0.8586 ± 0.0003	0.2470 ± 0.0005	0.2480 ± 0.0058	0.4102 ± 0.0003
11	KNN	KNN	dinov2_vitb14	0.9216 ± 0.0001	0.9671 ± 0.0001	0.8454 ± 0.0003	0.3125 ± 0.0005	0.3172 ± 0.0062	0.6357 ± 0.0013
12	MSP	MSP	dinov2_vitb14_lc	0.9063 ± 0.0003	0.9633 ± 0.0001	0.8089 ± 0.0003	0.3873 ± 0.0003	0.3889 ± 0.0055	0.5034 ± 0.0004
13	ASH-S	ASH-S	dinov2_vitb14_lc	0.8417 ± 0.0003	0.9194 ± 0.0001	0.7427 ± 0.0005	0.4921 ± 0.0007	0.4953 ± 0.0080	0.8925 ± 0.0026
14	DICE	DICE	dinov2_vitb14_lc	0.7943 ± 0.0000	0.8844 ± 0.0001	0.7250 ± 0.0001	0.4707 ± 0.0003	0.4742 ± 0.0023	0.7602 ± 0.0005
15	ASH-P	ASH-P	dinov2_vitb14_lc	0.7652 ± 0.0006	0.8874 ± 0.0002	0.5608 ± 0.0011	0.6964 ± 0.0006	0.6915 ± 0.0093	0.9325 ± 0.0001
16	NCI	NCI	dinov2_vitb14_lc	0.3169 ± 0.0001	0.6255 ± 0.0001	0.1843 ± 0.0000	0.9835 ± 0.0001	0.9833 ± 0.0007	1.1115 ± 0.0001
17	SCALE	SCALE	dinov2_vitb14_lc	0.2043 ± 0.0002	0.5824 ± 0.0001	0.1624 ± 0.0000	0.9787 ± 0.0001	0.9781 ± 0.0004	1.1653 ± 0.0001
18	ASH-B	ASH-B	dinov2_vitb14_lc	0.1887 ± 0.0002	0.5779 ± 0.0001	0.1583 ± 0.0000	0.9825 ± 0.0001	0.9831 ± 0.0006	1.1891 ± 0.0001

表 15: ImageNet-scale 補助実験の全結果: SSB-hard.

Rank	Display	Impl.	Backbone	AUROC	AUPR-IN	AUPR-OUT	FPR95-test	FPR95-val	AUTC
1	ViM	ViM	dinov2_vitb14_lc	0.8084 ± 0.0003	0.7687 ± 0.0002	0.8281 ± 0.0003	0.6185 ± 0.0004	0.6210 ± 0.0027	0.8843 ± 0.0001
2	Mahalanobis++	L2 MAF	dinov2_vitb14	0.7870 ± 0.0001	0.7573 ± 0.0002	0.7991 ± 0.0003	0.6710 ± 0.0003	0.6714 ± 0.0033	0.8912 ± 0.0036
3	MaxLogit	MaxLogit	dinov2_vitb14_lc	0.7687 ± 0.0005	0.7355 ± 0.0004	0.7609 ± 0.0004	0.7673 ± 0.0007	0.7690 ± 0.0053	0.8783 ± 0.0041
4	Energy	Energy	dinov2_vitb14_lc	0.7662 ± 0.0005	0.7331 ± 0.0004	0.7580 ± 0.0005	0.7732 ± 0.0006	0.7695 ± 0.0074	0.8755 ± 0.0048
5	GEN	GEN	dinov2_vitb14_lc	0.7640 ± 0.0005	0.7310 ± 0.0003	0.7540 ± 0.0004	0.7799 ± 0.0009	0.7770 ± 0.0087	0.8256 ± 0.0016
6	Entropy	Entropy	dinov2_vitb14_lc	0.7515 ± 0.0005	0.7163 ± 0.0004	0.7481 ± 0.0005	0.7732 ± 0.0010	0.7760 ± 0.0095	0.8516 ± 0.0003
7	ReAct	ReAct	dinov2_vitb14_lc	0.7394 ± 0.0005	0.7074 ± 0.0004	0.7247 ± 0.0005	0.8256 ± 0.0011	0.8176 ± 0.0124	0.8825 ± 0.0034
8	RMD	RMD	dinov2_vitb14	0.7366 ± 0.0002	0.6754 ± 0.0003	0.7826 ± 0.0002	0.6626 ± 0.0006	0.6642 ± 0.0062	0.8343 ± 0.0001
9	MSP	MSP	dinov2_vitb14_lc	0.7361 ± 0.0005	0.7069 ± 0.0005	0.7316 ± 0.0004	0.7917 ± 0.0005	0.7944 ± 0.0069	0.8002 ± 0.0004
10	KNN	KNN	dinov2_vitb14	0.7105 ± 0.0003	0.6828 ± 0.0002	0.7262 ± 0.0003	0.7939 ± 0.0006	0.7973 ± 0.0047	0.8510 ± 0.0004
11	Euclidean MAF	Euclidean MAF	dinov2_vitb14	0.7092 ± 0.0002	0.6540 ± 0.0002	0.7598 ± 0.0002	0.6826 ± 0.0008	0.6829 ± 0.0056	0.7934 ± 0.0002
12	MAF	MAF	dinov2_vitb14	0.7005 ± 0.0003	0.6330 ± 0.0006	0.7543 ± 0.0003	0.6892 ± 0.0009	0.6895 ± 0.0049	0.7783 ± 0.0020
13	ASH-P	ASH-P	dinov2_vitb14_lc	0.6763 ± 0.0007	0.6517 ± 0.0005	0.6864 ± 0.0008	0.8313 ± 0.0006	0.8273 ± 0.0076	0.9527 ± 0.0001
14	ASH-S	ASH-S	dinov2_vitb14_lc	0.6648 ± 0.0004	0.6470 ± 0.0004	0.6661 ± 0.0006	0.8575 ± 0.0006	0.8595 ± 0.0060	0.9514 ± 0.0012
15	DICE	DICE	dinov2_vitb14_lc	0.4988 ± 0.0000	0.4778 ± 0.0002	0.5298 ± 0.0002	0.9383 ± 0.0004	0.9423 ± 0.0031	0.9988 ± 0.0000
16	SCALE	SCALE	dinov2_vitb14_lc	0.4644 ± 0.0002	0.4578 ± 0.0006	0.5014 ± 0.0002	0.9493 ± 0.0001	0.9483 ± 0.0005	1.0042 ± 0.0009
17	ASH-B	ASH-B	dinov2_vitb14_lc	0.4429 ± 0.0002	0.4438 ± 0.0005	0.4848 ± 0.0001	0.9577 ± 0.0002	0.9593 ± 0.0016	1.0090 ± 0.0014
18	NCI	NCI	dinov2_vitb14_lc	0.4317 ± 0.0002	0.4442 ± 0.0002	0.4652 ± 0.0001	0.9720 ± 0.0001	0.9714 ± 0.0012	1.0295 ± 0.0001

B Limitations

本研究には複数の制約がある。第一に、WILD_DATA 主比較ではすべて同じ split で評価しているが、手法ごとに特徴 (feature)、ロジット (logits)、中間表現 (hidden representation) へのアクセスが異なる。これは学習後適用型 OOD 検知では避けにくい、完全に同一条件の比較ではない。第二に、本稿の 3 seed 平均は固定 split 上の seed 由来のばらつきを示すだけであり、split 再サンプリングやブートストラップによる性能推定の不確実性は測っていない。第三に、一部 baseline には診断的または oracle/tuned 設定が含まれる。本稿では固定 MAF を主結果にすることで過大主張を避けたが、baseline 側の hyperparameter selection policy はさらに整理が必要である。第四に、追加実験ではスコアヒストグラム、ROC/PR 曲線、失敗画像を示したが、画像レベルの解析は seed 42 を中心とするため、seed 間での失敗パターンの安定性は今後さらに確認する必要がある。

C 付録: baseline 実装詳細

表 16 に、本稿で比較した baseline のスコア定義と実装上のアクセスを整理する。学習後適用型 OOD 検知では、手法ごとに必要とする情報が異なる。MSP, Entropy, Energy, MaxLogit, GEN は分類器ロジットを使う。ReAct, ASH, DICE, SCALE, NCI, ViM はロジットに加えて中間特徴、活性 (activation)、分類器重み、残差部分空間 (residual subspace) などを使う。KNN, RMD, Mahalanobis++ は凍結特徴バンクまたはクラス統計量を使う。MAF は分類器ロジットを使わず、凍結 DINOv2 特徴、ID クラス平均、共有共分散だけを使う。なお、表中の後処理パラメータは既定値または本稿の主表に対応する設定を示すための備考であり、診断用 sweep で選ばれた値とは区別する。

C.1 比較の公平性

本稿の比較は、WILD_DATA の同一 split 上で各手法を再評価することを重視する。ただし、すべての手法が完全に同じ情報を使うわけではない。ロジット系手法は局所線形分類ヘッドの学習結果に依存する。特徴バンク系手法は大量の ID 特徴を保存し、近傍探索 (nearest neighbor search) または統計量推定を行う。活性整形 (activation shaping) 系手法は分類器の活性や重みに依存する。そのため、表の順位を「手法単体の純粋な優劣」としてではなく、「本稿の特徴抽出器、ヘッド、split、hyperparameter policy における実測値」として解釈する必要がある。

この点は MAF にも当てはまる。MAF はロジットを使わないため、ロジット系手法よりヘッド学習の揺らぎを受けにくい。一方で、クラス平均と共分散を安定に推定できる ID validation set が必要であり、クラス数が多い ImageNet-scale 設定では距離 softmax の性質が変わる。また、クラス別共分散 (class-wise covariance) は DINOv2 の 768 次元特徴では不安定になりやすい。したがって、MAF の利点は追加学習が不要 (training-free) であることではなく、凍結特徴上で ID クラス幾何を利用する学習後適用型スコアであることにある。

C.2 採用した結果表の切り分け

本稿では、WILD_DATA を主実験とし、ImageNet-1K/NINCO/SSB-hard を補助実験として扱う。この切り分けは重要である。WILD_DATA は 5 ID 種と 5 OOD 種からなる野生動物ドメインであり、ID/OOD が撮影条件、背景、体型、模様を強く共有するため、NINCO や SSB-hard よりも極端に近い Ultra-Near-OoD 設定として扱う。一方、ImageNet-1K 補助実験は 1,000 ID クラスを含み、NINCO と SSB-hard を OOD として用いる。この設定では MAF が AUROC 最良ではなく、ViM や Mahalanobis++ が強い。したがって、本稿の主張は WILD_DATA における MAF の有効性であり、ImageNet-scale への一般化は今後の課題として位置づける。

WILD_DATA 表においても、oracle または tuned 設定を含む行は慎重に扱う。固定 MAF は $\alpha = 0.50$, $\tau = 1.0$ 、生 DINOv2 特徴、共有共分散、Ledoit-Wolf 推定である。oracle check の MAF mah.t raw 行は、固定 MAF とほぼ同じ性能であるが、主結果としては採用しない。この扱いにより、test OOD label を使った過大評価を避ける。baseline 側に tuned 設定が含まれる場合は、caption または本文でその旨を明記する。

C.3 再現性のための記録項目

再現性のためには、seed, split, 前処理、特徴抽出器、ヘッド、共分散、スコア方向、指標計算を明記する必要がある。本稿では seed を 3 つ用い、値は平均 $\pm$ 標準偏差で報告する。スコアは高いほど ID らしい方向に統一する。AUROC, AUPR-IN, AUPR-OUT は高いほど良く、FPR95 と AUTC は低いほど良い。数値は小数第五位を四捨五入し、表では小数 4 桁で表示する。共分散逆行列の計算では、高次元特徴での数値不安定性を避けるために正則化を行う。実画像や dataset を公開または掲載する場合は、dataset source, split 作成手順、重複除外の有無を記載する必要がある。

表 16: baseline のスコア定義と実装上のアクセス. スコアは高いほど ID らしい方向にそろえている. パラメータ欄は既定値 (source-default) または本稿で用いた主な設定を示す.

Method	Access	スコア概要	パラメータ/備考
MSP	logits	最大 softmax 確率を ID スコアとする	none
Entropy	logits	負の予測エントロピー (negative predictive entropy) を ID スコアとする	none
Energy	logits	ロジット上の指数和对数 (log-sum-exp) を ID スコアとする	temperature 1.0
MaxLogit	logits	最大ロジットを ID スコアとする	none
GEN	logits	上位 softmax 確率から一般化エントロピースコアを計算する	$\gamma = 0.1$, $\text{top-}M = \min(100, K) = 5$
ReAct	activation, logits	ID 活性の percentile で上限を切り詰め, Energy スコアを計算する	既定: train hidden p90; 診断 sweep あり
ASH-B/P/S	activation, logits	活性整形 (activation shaping) 後に Energy スコアを計算する	variant 依存; B/P は p65, S は p90/95
DICE	feature, weight, logits	contribution に基づき weight/feature を sparsify し, Energy スコアを計算する	p70/p90; 診断 sweep あり
SCALE	activation, logits	活性刈り込み (activation pruning) と scale correction 後に Energy スコアを計算する	p85
ViM	feature, logits	残差部分空間ノルム (residual subspace norm) と仮想ロジット (virtual logit) を組み合わせる	診断設定; DIM と α は ID train で fit
KNN	feature bank	正規化特徴空間で k 近傍類似度を ID スコアとする	WILD 主表は $k = 1$; 診断 sweep あり
RMD	feature statistics	global Mahalanobis 距離と class Mahalanobis 距離の差を使う	class/global 統計と λ は variant 依存
Mahalanobis++	normalized statistics	ℓ_2 正規化特徴上で train/id 平均と共有経験共分散を用いた最近傍二乗 Mahalanobis 距離の負値を使う	L2 feature
MAF	feature statistics	distance-softmax から $\text{conf}(x)$ と $\text{cons}(x)$ を作り幾何融合する	tied covariance, $\tau = 1.0$, $\alpha = 0.50$