

野生動物 Near-OOD 検知における 凍結視覚 Backbone と Mahalanobis 距離設計の検証

d-hacks B3.0 omote 親:zackey さん

概要

野生動物画像認識では、未知種が既知種と外観的・意味的に近い場合が多く、分類器が未知種を高確信で既知種として受取する near-OOD 問題が生じる。本稿では、凍結済み vision backbone の特徴空間において、正則化 Mahalanobis 距離に基づく OOD score 設計が野生動物 near-OOD 検知にどの程度有効かを検証する。具体的には、ID validation set から推定したクラス平均と共有共分散に基づき、各入力から全 ID クラスへの Mahalanobis 距離ベクトルを計算し、その相対分布から ID らしさを定義する MAF score を評価する。5 ID 種と 5 OOD 種からなる固定 split では、DINOv2-ViT-B/14 上で MAF は AUROC 0.8922, FPR95 0.5157 を示し、ASH-P, SCALE, GEN, KNN, ViM などの非 Mahalanobis 系 post-hoc 手法を上回った。一方、Mahalanobis++ 型の L2 正則化 MAF も DINOv2 で AUROC 0.8904 と競合的であり、ImageNet-ViT では通常 MAF を上回った。また、BioCLIP では GEN が AUROC で最良となった。したがって、本稿の結論は、MAF が一般に最良であるというものではなく、凍結 DINOv2 など一部の特徴空間では、正則化 Mahalanobis 距離分布が野生動物 near-OOD の順位性能と FPR95 を改善するが、最適な距離設計と正則化は backbone に依存する、という限定的なものである。




図 1: OOD 検知における過信の問題

1 序論

深層画像分類器は、学習時に定義されたクラス集合の中から入力画像のラベルを予測するクローズドセット認識を前提として発展してきた。しかし、実環境では、学習時に含まれていない対象が入力されることがある。このような入力は out-of-distribution (OOD) データと呼ばれ、OOD 検知では、入力 x が ID 分布 D_{in} に属するか、OOD 分布 D_{out} に属するかを判定するための score $s(x)$ を構成する [1, 2, 3]。

野生動物画像では、この問題が構造的に難しくなる。カメラトラップ画像には、照明、姿勢、遮蔽、背景、撮影距離の大きな変動が含まれる。さらに、実運用で現れる未知種は、ID 種と全く無関係な物体ではなく、既知種と意味的・視覚的に近い動物であることが多い。例えば、学習時に leopard を含まない分類器が、leopard 画像を cheetah として高確信で受取する可能性がある。このような near-OOD は、遠方 OOD よりも分類器にとって識別が難しく、softmax 確信度だけにに基づく判定では誤受取が生じやすい。

本稿では、凍結済み vision backbone の特徴空間に着目する。DINOv2 や CLIP などの backbone は、分類 head を再学習しなくても有用な視覚特徴を与える。一方で、OOD 検知では、分類 logits だけでなく、特徴空間における ID クラスとの幾何的な関係も重要になりうる。そこで本稿では、ID validation set から各 ID クラスの平均と共有共分散を推定し、入力特徴から各クラスへの正則化 Mahalanobis 距離を計算する。さらに、単一の最小距離だけでなく、全 ID クラスへ

の距離ベクトルを相対分布へ変換し、その集中度と鋭さから MAF score を構成する。ここでの中心的な問いは、MAF が一般に最良かどうかではなく、凍結特徴上の Mahalanobis 距離分布が野生動物 near-OOD においてどの条件で有効になるかである。

本稿の主張は、MAF があらゆる状況で最良になるというのではない。主比較では、DINOv2-ViT-B/14 において MAF が softmax/logit 系、feature 系、activation shaping 系の代表的な手法より高い AUROC と低い FPR95 を示した。一方で、BioCLIP では GEN が AUROC で最良となり、DINOv2 でも AUROC では GEN が MAF を上回る。さらに、Mahalanobis++ 型の L2 正則化 MAF は DINOv2 で通常 MAF とほぼ同等、ImageNet-ViT では通常 MAF を上回る。したがって、本稿の中心的な主張は、凍結 DINOv2 など一部の特徴空間では、Mahalanobis 距離に基づく設計が野生動物 near-OOD の順位性能と FPR95 を改善するが、その効果は backbone と特徴正則化に依存する、という限定されたものである。FPR95 も 0.5157 に留まるため、未知種を安全に棄却できるとまでは主張しない。

本稿の貢献は以下である。

1. 野生動物 near-OOD 検知に対して、凍結 backbone の生特徴上で、全 ID クラスへの正則化 Mahalanobis 距離ベクトルを相対分布として扱う post-hoc score を定義する。
2. 5 ID 種・5 OOD 種からなる近接種設定において、DINOv2, ImageNet-ViT, OpenAI CLIP, BioCLIP を比較し、DINOv2 など一部の特徴空間では Mahalanobis 系設計が非 Mahalanobis 系手法より AUROC と FPR95 を改善することを示す。
3. Mahalanobis++ 型正則化、BioCLIP での限界、OOD 種別の nearest-ID 解析、false accept 例を通じて、Mahalanobis 系 OOD score の有効範囲と限界を明らかにする。

2 関連研究

2.1 Softmax・logit に基づく OOD 検知

MSP は最大 softmax 確率を ID らしさとして用いる基本手法である [1]。ODIN は温度スケールと入力摂動により softmax 分布の差を強調する [2]。Energy score は logit の log-sum-exp を用いることで、softmax 確率だけでなく

logit 全体の大きさを反映する [3]. GEN は softmax 分布の一般化エントロピーに基づく post-hoc スコアであり、大規模 ImageNet 系評価で強い softmax-based baseline として報告されている [4]. 本稿では、これらを分類 head の出力に基づく代表的な比較対象として用いる. 特に BioCLIP では GEN が AUROC で最良となるため、softmax/logit 系手法は単なる弱い baseline ではなく、backbone によっては有効な選択肢として扱う.

2.2 特徴空間に基づく OOD 検知

Mahalanobis 法は、特徴空間上のクラス平均と共分散を推定し、クラス条件付き Gaussian discriminant analysis に基づいて OOD を検知する [5]. 近年は、単純な Mahalanobis 距離の near-OOD 性能を改善する RMD [6] や、特徴正規化により Mahalanobis 推定を安定化する Mahalanobis++ [7] が提案されている. 本稿の MAF は Mahalanobis 距離を用いるが、単一の最小距離をそのまま ID score とするのではなく、全 ID クラスへの距離ベクトルを相対分布へ変換し、その集中度と鋭さから score を構成する点異なる. また、DINOv2 と ImageNet-ViT では Mahalanobis++ 型の L2 正規化も ablation に含め、通常の共有共分散 MAF との違いを比較する.

kNN OOD は学習特徴集合への近傍距離を用いる non-parametric な手法であり、分布仮定に依存しない強みを持つ [8]. ViM は特徴空間の residual と logit 情報を仮想 logit として統合する [9]. 本稿ではこれらの特徴空間系の比較対象に含める. MAF は特徴空間を用いる点では同じだが、学習サンプル全体への近傍探索や分類 head の重みに依存せず、validation set から推定した ID クラス平均と共有共分散だけで score を計算する.

2.3 特徴活性整形と近年の post-hoc 手法

ReAct は特徴活性のクリッピングにより OOD 入力に対する過大な活性を抑制する [10]. DICE は寄与の小さい重みを削ることで OOD 検知性能を改善する [11]. ASH は late-layer activation を刈り込み、再スケーリングする簡潔な post-hoc 手法である [12]. SCALE は activation shaping の効果を scaling として整理し、post-hoc OOD 検知を改善する [13]. NCI は neural collapse の観点から特徴と分類重みの関係を利用する [14]. OODD は test-time に動的辞書を構築する手法である [15]. 本稿では、これらを近年の post-hoc OOD 検知手法として比較する. ただし本実験では、凍結 backbone から抽出した cached feature と local classifier を用いるため、公式実装が想定する ImageNet classifier の中間層とは完全には一致しない. したがって、結果は本設定における post-hoc 比較として解釈し、公式ベンチマークの完全再現とは区別する.

2.4 凍結 vision backbone と野生動物画像

CLIP は画像と言語の対照学習により汎用的な視覚表現を獲得する [16]. DINOv2 は大規模な自己教師あり学習により頑健な視覚特徴を学習する [17]. BioCLIP は生物画像と分類階層を用いた vision foundation model である [18]. 野生動物画像では、同一種内の姿勢・背景変動と、異種間の外観類似が同時に生じるため、backbone の特徴空間が OOD 検知性能を大きく左右する. 本稿では、backbone を再学習せず、生特徴に対する Mahalanobis 距離分布型の post-hoc score を評価する.

3 Mahalanobis 距離分布スコア

3.1 問題設定

ID クラス集合を $\mathcal{C} = \{1, \dots, C\}$ とする. 入力画像 x に対して凍結済み backbone から特徴ベクトル

$$h(x) \in \mathbb{R}^d \quad (1)$$

を抽出する. 本研究の主設定では $C = 5$ である. MAF は分類 logits ではなく、凍結 backbone の生特徴 $h(x)$ 上で定義される. したがって、backbone の再学習や OOD データによる tuning を必要としない. validation set で推定した ID クラスの統計量を固定し、test 時には入力特徴と各 ID クラスとの距離だけから ID score を計算する.

3.2 正則化 Mahalanobis 距離

ID validation set を $D_{\text{val}}^{\text{ID}}$ とする. クラス c の validation 特徴集合を

$$V_c = \{h(x_i) \mid y_i = c, (x_i, y_i) \in D_{\text{val}}^{\text{ID}}\} \quad (2)$$

とし、クラス平均を

$$\mu_c = \frac{1}{|V_c|} \sum_{h_i \in V_c} h_i \quad (3)$$

とする. 各クラスの共分散を $\Sigma_c = \text{Cov}(V_c)$ とし、共有共分散を

$$\Sigma_{\text{tied}} = \frac{1}{C} \sum_{c=1}^C \Sigma_c \quad (4)$$

とする. 高次元特徴では共分散推定が不安定になりやすいため、縮小推定により

$$\tilde{\Sigma} = (1 - \rho)\Sigma_{\text{tied}} + \rho \frac{\text{tr}(\Sigma_{\text{tied}})}{d} I_d \quad (5)$$

を用いる [19]. 入力 x のクラス c への Mahalanobis 距離は

$$d_c(x) = \sqrt{\{h(x) - \mu_c\}^\top \tilde{\Sigma}^{-1} \{h(x) - \mu_c\}} \quad (6)$$

である.

3.3 距離分布と融合スコア

距離が小さいほどクラス c に近いことを表すため、温度 τ を用いて

$$p_c(x) = \frac{\exp(-d_c(x)/\tau)}{\sum_{k=1}^C \exp(-d_k(x)/\tau)} \quad (7)$$

を定義する. 本稿の主設定では $\tau = 1$ とする. $p_c(x)$ は分類器の softmax ではなく、Mahalanobis 距離から作られるクラス相対分布である. すなわち、入力がどの ID クラスに最も近いだけでなく、他の ID クラスからどの程度相対的に離れているかも score に反映される. 最近傍クラスへの集中度を

$$s_{\text{conf}}(x) = \max_{c \in \mathcal{C}} p_c(x) \quad (8)$$

とし、正規化エントロピー

$$H_n(x) = -\frac{1}{\log C} \sum_{c=1}^C p_c(x) \log(p_c(x) + \varepsilon) \quad (9)$$

から、分布全体の鋭さを

$$s_{\text{cons}}(x) = 1 - H_n(x) \quad (10)$$




図 2: Mahalanobis 距離分布スコアの全体図




図 3: 特徴空間の操作の詳細

とする。最終的に、固定係数 $\alpha \in [0, 1]$ により

$$S_{MAF}(x) = s_{conf}(x)^\alpha s_{cons}(x)^{1-\alpha} \quad (11)$$

を得る。主実験では、test OOD による係数選択を避けるため $\alpha = 0.75$ とする。DINOv2 では $\alpha = 0$ と $\alpha = 0.75$ の差は小さいため、本稿では融合係数そのものを主要な貢献とはせず、正則化 Mahalanobis 距離が凍結特徴上で有効に働くことを中心的な主張とする。

3.4 距離分布スコアの限界

距離分布 $p_c(x)$ は、距離ベクトル全体に同じ定数を足しても変わらない。したがって、全 ID クラスから絶対的に遠い入力と、全 ID クラスに近い入力、類似した相対分布を持つ可能性がある。この性質は near-OOD ではクラス間の相対関係を捉える利点になりうる一方、遠方 OOD や背景画像では絶対距離情報を弱める限界にもなる。このため、本稿では Euclidean fusion, 最小 Mahalanobis 距離, log-sum-exp 距離, L2 正則化を含む距離設計の ablation を示し、MAF の主効果と限界を切り分ける。また、confidence と consistency は同じ距離分布から計算されるため高く相関する。本稿では両者を独立な情報源とはみなさず、高相関な二つの要約量を固定係数で組み合わせる実装上の選択として扱う。

4 実験設定

4.1 データセット

ID クラスは buffalo, cheetah, elephant, giraffe, hippo の 5 種、OOD クラスは impala, leopard, lion, rhino, wildebeest の 5 種である。各 split の枚数を表 1 に示す。OOD クラスは ID クラスと外観的に近い種を含むため、near-OOD の評価に適している。例えば、leopard は cheetah, impala は giraffe, wildebeest は buffalo と視覚的・意味的に近く、単純な far-OOD ではなく、実運用上の誤受理を評価しやすい設定である。

本稿の主評価は、あらかじめ作成された固定 split に基づく。prepared split の監査では、train split に存在するのは 5 つの ID 種のみであり、OOD 種は val/test split には存在するが train split には存在しなかった。また、現在の prepared split

表 1: データセット構成。

Split	枚数
train/id	45,941
val/id	10,000
val/ood	10,000
test/id	10,000
test/ood	10,000

には camera ID, event ID, location ID などのメタデータが含まれていない。そのため、camera-level split, event-level split, location-held-out split, および複数 ID 種 split は、現在の prepared split だけでは生成できない。これらの検証には raw WILD 画像と撮影メタデータに戻った split 再生成が必要である。本稿ではこの制約を明記し、固定 split 上での near-OOD 性能、OOD 種別解析, false accept 解析によって、現時点で評価可能な範囲を補う。

再現性のため、使用したデータセットと split は https://drive.google.com/drive/folders/1LCdZnAN6gWIV_Ds0bTWLipD6jjptLAgj?usp=share_link で公開し、実験コードと生成済み論文 PDF は <https://github.com/omotes24/MAF01> で公開する。

4.2 Backbone

表 2 の 4 種類を主実験で用いる。各 backbone は凍結し、MAF は backbone から得られる生特徴のみに適用する。比較手法の一部では local MLP head の logits や penultimate feature を用いるが、MAF 本体は分類 head を用いない。補助実験では ResNet50 も評価し、backbone 依存性を確認した。

4.3 比較手法と評価指標

比較対象は MSP, Entropy, Energy, MaxLogit, GEN, KNN, ViM, ReAct, DICE, ASH, SCALE, NCI, OODD, RMD とする。GEN は softmax 確率のみから計算されるた

表 2: 主な backbone 設定.

Backbone	特徴次元 d
ImageNet-ViT	768
BioCLIP	512
DINOv2-ViT-B/14	768
OpenAI CLIP-B/16	512

め、公式設定に最も近い形で評価できる．一方で、ReAct, ASH, SCALE, DICE, ViM, NCI は元論文が想定する中間層や classifier 構造と、本実験の cached feature および local MLP head が完全には一致しない場合がある．そのため、本稿では公式の score 方向、主要式、代表的な source-default hyperparameter を確認したうえで、local head feature へ写像した結果として報告する．Mahalanobis++型の L2 正規化 MAF は、競合手法というより距離設計上の重要な比較軸として扱い、主結果表と距離設計 ablation の両方に示す．あわせて、hyperparameter sweep で得た best-by-method の結果も診断的に確認するが、主張では source-default または明示した設定を優先する．

評価指標は AUROC, AUPR-IN, AUPR-OUT, FPR95, AUTC とする．表中では、列名の $\uparrow$ が高いほど良い指標、 $\downarrow$ が低いほど良い指標を表す．本稿の主張は AUROC と FPR95 を中心に置く．AUTC は閾値全体での誤受理率・誤棄却率を反映する補助指標として扱い、GEN が有利な場合があることを結果節で明記する．

5 結果

5.1 全体結果

表 4 に、各 backbone での最良の Mahalanobis 系設計と、最良の非 Mahalanobis 系 baseline を要約する．ここでの Mahalanobis 系には、通常の MAF、最小 Mahalanobis 距離、Mahalanobis++型 L2 正規化 MAF を含む．非 Mahalanobis 系 baseline は、softmax/logit 系、feature 系、activation shaping 系の代表的手法を指す．DINOv2-ViT-B/14 では、通常 MAF が AUROC 0.8922, FPR95 0.5157 を示し、非 Mahalanobis 系 baseline を明確に上回った．ImageNet-ViT では、通常 MAF ではなく Mahalanobis++ L2 MAF が最良であり、OpenAI CLIP-B/16 でも通常 MAF と Mahalanobis++ L2 MAF は近い．

一方、BioCLIP では GEN が AUROC 0.8080 で最良であり、通常 MAF は 0.8031 に留まる．また、BioCLIP の FPR95 は SCALE が 0.7159 で最良であり、通常 MAF は 0.7327 である．したがって、本稿の結果は「MAF が一般に最良」という主張ではなく、「野生動物 near-OOD では、backbone によって Mahalanobis 距離設計が有効になる場合がある」という主張を支持する．

5.2 DINOv2 での詳細比較

表 5 に DINOv2 の詳細結果を示す．この表では、MAF を softmax/logit 系、feature 系、activation shaping 系の代表的 baseline と比較する．MAF は AUROC, AUPR-IN, AUPR-OUT, FPR95 で最良であり、ASH, SCALE, ReAct, GEN, ViM, ODD, NCI などを上回る．ただし、Mahalanobis++型正規化との比較は表 6 および Appendix で別に扱い、AUTC では GEN が 0.7219 で最良である．したがって、本稿の主張

は、DINOv2 では Mahalanobis 距離に基づく設計が非 Mahalanobis 系 baseline に対して順位性能と FPR95 で強い、という範囲に限定する．

ReAct, ASH, SCALE, DICE, ViM, NCI は、公式の score 方向と主要式を確認したうえで再実装した．ただし、本実験では各公式実装が想定する ImageNet classifier の中間層ではなく、本リポジトリの local classifier hidden feature に適用している．このため、表 5 は手法間比較として有用だが、公式ベンチマークの完全再現ではない点を明記する．

5.3 Mahalanobis 距離と融合の切り分け

表 6 に、DINOv2 と ImageNet-ViT における距離・共分散設計の ablation を示す．DINOv2 では、Euclid fusion の AUROC 0.8031 に対し、Mahalanobis MAF は 0.8922 である．ImageNet-ViT でも、Euclid fusion 0.7780 に対し、通常の MAF は 0.8453, L2 正規化を入れた Mahalanobis++型 MAF は 0.8598 である．この差は、単に距離ベクトルを softmax 化したことではなく、共分散を考慮した Mahalanobis 距離と特徴正規化が性能に強く影響することを示唆する．

一方で、DINOv2 では $\alpha = 0$ と $\alpha = 0.75$ の差は非常に小さく、Mahalanobis++型 MAF も AUROC 0.8904 と MAF 0.8922 に極めて近い．したがって、本稿では「confidence と consistency の融合が常に大きな改善をもたらす」とは主張しない．現段階では、固定 $\alpha = 0.75$ は OOD test tuning を避けた安定な設定であり、主効果は正則化 Mahalanobis 距離にある、と整理する．また、ImageNet-ViT では Mahalanobis++型 MAF が通常の MAF を上回っており、backbone によって適切な距離設計や正規化が異なる可能性がある．計算量の観点では、通常 MAF の推論時支配項は全 ID クラスへの Mahalanobis 距離計算であり、1 入力あたり $O(Cd^2)$ である．Mahalanobis++型 MAF はこれに特徴の L2 正規化 $O(d)$ を追加するため理論上はわずかに重い、支配項は同じ $O(Cd^2)$ であり、本実験の $C = 5$, $d = 512$ または 768 では実用上ほぼ同等である．

5.4 実測計算時間

表 7 に、backbone forward と score 計算を含む end-to-end 推論時間を示す．計測では data loading を除外し、GPU1 上で batch size 64 として、seed 42 の評価 split を用いた．MAF は MSP より score 計算が重い、画像 1 枚あたりの forward を含めると、平均 overhead は 0.118 ms/img, 2.91% であった．したがって、本実験規模では、MAF の追加コストは backbone forward に比べて小さい．

なお、表 7 の MAF は固定係数 $\alpha = 0.75$ の通常 MAF である．Mahalanobis++型 MAF は特徴の L2 正規化を追加するため、理論上は通常 MAF より $O(d)$ だけ重い、支配項は同じ $O(Cd^2)$ であり、この表の測定条件では通常 MAF と同程度の計算時間になると解釈できる．

5.5 スコア分布と失敗例

図 6 に、DINOv2 と BioCLIP での ID/OOD スコア分布を示す．DINOv2 では ID と OOD の分布が比較的分離しており、これが DINOv2 で MAF が高い AUROC を示す主因である．一方、BioCLIP では分布の重なりが大きく、GEN や SCALE が MAF を上回る結果と整合する．

図 4 に、 α と 2 成分の関係を示す．DINOv2 の best α は 0.51, BioCLIP の best α は 0.72 であった．confidence 成分と consistency 成分の Pearson 相関は、DINOv2 で ID $r = 0.962$ /OOD $r = 0.926$, BioCLIP で ID $r = 0.954$ /OOD $r = 0.916$ であり、両成分は強く相関する．したがって、両者

表 3: 主張と対応する検証

主張	実験または図表	本稿での扱い
DINOv2 では Mahalanobis 距離に基づく設計が有効である	DINOv2 の全 baseline 表, Mahalanobis++ 比較, 画像単位 bootstrap 信頼区間	結果節の DINOv2 詳細表, 距離・共分散 ablation 表, Appendix の系統別比較表
距離設計と正規化の影響を切り分ける confidence と consistency の関係を確認する OOD test による tuning を避ける	Mahalanobis と Euclid, confidence/consistency/fusion, tied/diagonal/per-class covariance, Mahalanobis++ の比較 $s_{\text{conf}} - s_{\text{cons}}$ 散布図, 相関係数, ID/OOD 別 histogram, α sweep 固定 $\alpha = 0.75$ を主設定とし, α sweep は診断図として分離	結果節の ablation 表, 考察節の距離設計の整理 結果節の score 分布図, 融合係数と 2 成分の関係図 結果節の ablation 表, 融合係数と 2 成分の関係図
野生動物実運用に近い near-OOD 評価である split 依存性の限界を明示する 計算上実用的である	OOD 種別 score 分布, nearest ID class 解析, false accept 上位画像 prepared split の train/val/test 構成監査, raw metadata の有無確認 score 時間と end-to-end 時間, KNN/OOD との比較	結果節・考察節の OOD 種別図, false accept 例 本節およびデータ監査結果として記述 結果節の計算時間表

表 4: 各 backbone における主比較の要約. Mahalanobis 系設計と非 Mahalanobis 系 baseline を分けて示す. 列名の $\uparrow$ は高いほど良く, $\downarrow$ は低いほど良いことを表す.

Backbone	Best Mahalanobis design	Best non-Mah AUROC $\uparrow$	Best non-Mah FPR95 $\downarrow$	解釈
BioCLIP	MAF: AUROC 0.8031, FPR95 0.7327	GEN 0.8080	SCALE 0.7159	非 Mahalanobis 系が最良
DINOv2-ViT-B/14	MAF: AUROC 0.8922, FPR95 0.5157	ASH-P 0.8397	ReAct 0.5743	Mahalanobis 距離分布が最も明確に有効
ImageNet-ViT	Mahalanobis++ L2 MAF: AUROC 0.8598, FPR95 0.6186	ASH-P 0.8091	ASH-P 0.6849	L2 正規化が通常 MAF を上回る
OpenAI CLIP-B/16	Mahalanobis++ L2 MAF: AUROC 0.8315, FPR95 0.6821	GEN 0.7971	ASH-P 0.7242	通常 MAF と L2 MAF は近い

を完全に独立な情報源としては扱わず, 高相関だが同一ではない score として, 重み付けによって順位性能が変化する点を主張する.

図 7 と図 8 に, OOD 種別の近傍 ID クラスと false accept 上位例を示す. DINOv2 では impala の 85.1% が giraffe, leopard の 68.4% が cheetah, wildebeest の 86.5% が buffalo に最も近くなる. false accept 上位例でも leopard が cheetah 側に寄る例が多く, near-OOD として意味的・視覚的に近い種が誤受理されやすいことが確認できる.

6 考察

6.1 DINOv2 で Mahalanobis 距離分布が強い理由

DINOv2 では, 自己教師あり学習により得られた特徴が, 野生動物種の形状, 姿勢, 局所構造を比較的安定に表現している可能性がある. この性質により, クラス平均と共有共分散に基づく Mahalanobis 距離が, softmax や activation shaping よりも ID/OOD の順位付けに有効だったと考えられる. 実際, DINOv2 では MAF($\alpha = 0.75$) が AUROC 0.8922, FPR95 0.5157 を示し, Energy や ASH-P などの非 Mahalanobis 系手法を上回った. ただし, Mahalanobis++ 型 MAF も AUROC 0.8904 と近いので, DINOv2 での結果は, MAF 固有の融合だけでなく, 正則化 Mahalanobis 距離を基盤とする設計全体の有効性として解釈するのが妥当である.

図 5 に示す t-SNE でも, DINOv2 では ID 種のクラスタが比較的近い, OOD 種は近い ID クラスの周辺または間に配置される傾向が見える. この構造では, 単一の maximum softmax probability よりも, ID クラス全体に対する相対的な距離分布を使う MAF が有利になりやすい. ただし, これは DINOv2 の特徴空間に依存した結果であり, すべての backbone で同じ挙動を仮定すべきではない.

6.2 BioCLIP での限界

BioCLIP は生物分類に特化しているため, 未知種を分類階層上の近い既知種の近傍へ配置しやすい可能性がある. この場合, Mahalanobis 距離分布だけでは OOD を十分に分離できず, softmax 分布の形状を用いる GEN が有利になる場合がある. 実際, BioCLIP では GEN が AUROC 0.8080 で最良であり, MAF は 0.8031 に留まった. FPR95 でも SCALE が 0.7159 で最良であり, MAF は 0.7327 であった.

図 6 では, BioCLIP の ID/OOD score 分布は DINOv2 より重なりが大きい. これは, BioCLIP が生物種として意味的に近い OOD を ID 近傍に埋め込むことと整合する. したがって, BioCLIP の結果は MAF の単純な失敗ではなく, backbone の特徴空間構造によって最適な OOD score が変わることを示す重要な結果である.

6.3 絶対距離情報の必要性

MAF は距離ベクトルを相対分布へ変換するため, 絶対的な遠さを弱める可能性がある. near-OOD では相対的なクラス関係が効く一方で, 遠方 OOD や背景のみの画像では, $\min_c d_c(x)$ のような絶対距離や特徴正規化が重要になる可能性がある. この点を切り分けるため, 最小 Mahalanobis 距離, log-sum-exp 距離, Euclidean fusion, diagonal covariance, per-class covariance, Mahalanobis++ 型 L2 正規化を比較した.

DINOv2 では, MAF($\alpha = 0.75$) の AUROC 0.8922 に対し, Mahalanobis++ L2 MAF は 0.8904 であり, ほぼ同等の競合的性能を示した. 一方, Euclidean fusion は 0.8031, Mah-MinDist は 0.7761, Mah-LSE は 0.7660 に留まるため, DINOv2 では単純な絶対距離よりも, 共有共分散を用いた Mahalanobis 距離分布が重要である. ImageNet-ViT では Mahalanobis++ L2 MAF が 0.8598 となり, 通常の MAF 0.8453 を上回った. この結果は, MAF の優位性を単一設計として固定的に主張するよりも, Mahalanobis 距離を基盤としつつ,

表 5: DINOv2-ViT-B/14 における詳細比較. 値は 3 seed 平均 $\pm$ 標準偏差. 列名の $\uparrow$ は高いほど良く, $\downarrow$ は低いほど良いことを表す.

Method	AUROC $\uparrow$	AUPR-IN $\uparrow$	AUPR-OUT $\uparrow$	FPR95 $\downarrow$	AUTC $\downarrow$
MAF $\alpha = 0.75$	0.8922 $\pm$ 0.0000	0.8994 $\pm$ 0.0000	0.8784 $\pm$ 0.0000	0.5157 $\pm$ 0.0001	0.7641 $\pm$ 0.0000
ASH-P	0.8397 $\pm$ 0.0311	0.8278 $\pm$ 0.0325	0.8424 $\pm$ 0.0314	0.5837 $\pm$ 0.0544	0.8686 $\pm$ 0.0154
Energy	0.8396 $\pm$ 0.0310	0.8275 $\pm$ 0.0327	0.8418 $\pm$ 0.0309	0.5841 $\pm$ 0.0538	0.8560 $\pm$ 0.0133
ReAct	0.8379 $\pm$ 0.0304	0.8268 $\pm$ 0.0386	0.8397 $\pm$ 0.0269	0.5743 $\pm$ 0.0443	0.8959 $\pm$ 0.0171
SCALE	0.8355 $\pm$ 0.0309	0.8232 $\pm$ 0.0321	0.8367 $\pm$ 0.0313	0.6090 $\pm$ 0.0532	0.8875 $\pm$ 0.0130
ASH-S	0.8357 $\pm$ 0.0310	0.8235 $\pm$ 0.0319	0.8372 $\pm$ 0.0318	0.6082 $\pm$ 0.0549	0.8739 $\pm$ 0.0130
KNN	0.7930 $\pm$ 0.0000	0.8065 $\pm$ 0.0000	0.7678 $\pm$ 0.0000	0.7277 $\pm$ 0.0000	0.8120 $\pm$ 0.0000
OODD	0.7923 $\pm$ 0.0082	0.8185 $\pm$ 0.0102	0.7378 $\pm$ 0.0087	0.8377 $\pm$ 0.0195	0.7922 $\pm$ 0.0042
GEN	0.7851 $\pm$ 0.0137	0.7920 $\pm$ 0.0131	0.7276 $\pm$ 0.0098	0.8557 $\pm$ 0.0045	0.7219 $\pm$ 0.0213
ViM	0.7719 $\pm$ 0.0180	0.7999 $\pm$ 0.0266	0.7244 $\pm$ 0.0063	0.8403 $\pm$ 0.0113	0.9606 $\pm$ 0.0028
DICE	0.7637 $\pm$ 0.0158	0.7609 $\pm$ 0.0195	0.7057 $\pm$ 0.0123	0.8721 $\pm$ 0.0072	0.8246 $\pm$ 0.0165
ASH-B	0.7538 $\pm$ 0.0218	0.7275 $\pm$ 0.0205	0.7480 $\pm$ 0.0200	0.7575 $\pm$ 0.0225	0.9222 $\pm$ 0.0136
NCI	0.6930 $\pm$ 0.0150	0.7014 $\pm$ 0.0131	0.6494 $\pm$ 0.0106	0.8856 $\pm$ 0.0056	0.9196 $\pm$ 0.0031

表 6: 距離, 共分散, 融合係数に関する ablation. 式の定義上, $\alpha = 1$ は confidence のみ, $\alpha = 0$ は consistency のみに対応する.

Backbone	Method	AUROC $\uparrow$	AUPR-OUT $\uparrow$	FPR95 $\downarrow$
DINOv2	MAF $\alpha = 0.75$	0.8922	0.8784	0.5157
	MAF $\alpha = 0$	0.8921	0.8788	0.5171
	Mahalanobis++ L2 MAF	0.8904	0.8759	0.5217
	MAF $\alpha = 1$	0.8854	0.8670	0.5623
	Euclid fusion $\alpha = 0.75$	0.8031	0.7296	0.8512
	Energy	0.8396	0.8418	0.5841
ImageNet-ViT	Mahalanobis++ L2 MAF	0.8598	0.8339	0.6186
	MAF $\alpha = 1$	0.8457	0.8115	0.6928
	MAF $\alpha = 0.75$	0.8453	0.8145	0.6739
	MAF $\alpha = 0$	0.8393	0.8103	0.6780
	Euclid fusion $\alpha = 0.75$	0.7780	0.7438	0.7927
	Energy	0.8090	0.7969	0.6855

表 7: backbone forward を含む end-to-end 推論時間の実測値. data loading は除外し, GPU1, batch size 64 で計測した.

Backbone	Forward ms/img	MSP ms/img	MAF ms/img	Ratio vs. MSP	Overhead ms/img	Overhead %
DINOv2	4.506	4.658	4.907	1.054 $\times$	0.250	5.36
ImageNet-ViT	3.449	3.542	3.639	1.027 $\times$	0.097	2.75
OpenAI CLIP-B/16	3.429	3.521	3.583	1.018 $\times$	0.062	1.77
BioCLIP	3.465	3.560	3.623	1.018 $\times$	0.064	1.79
Mean	3.712	3.820	3.938	1.029$\times$	0.118	2.91

backbone に応じた特徴正規化が有効になりうることを示している.

6.4 誤受理の構造

図 7 に, OOD 種ごとの nearest-ID 分布と MAF score 分布を示す. DINOv2 では, impala の 85.1% が giraffe, leopard の 68.4% が cheetah, wildebeest の 86.5% が buffalo に最も近くなる. この結果は, 距離分布スコアの誤受理が無作為ではなく, 視覚的・意味的に近い ID 種への吸収として現れることを示す.

図 8 の false accept 上位例でも, leopard が cheetah 側に寄る例が多い. したがって, 実運用上の課題は, 完全に異なる画像を弾くことだけでなく, 既知種に近い未知種をどこまで安全に棄却できるかにある. DINOv2 の MAF は AUROC を大きく改善するが, FPR95 は 0.5157 であり, ID 95% 受理の閾値では OOD の約半数を誤受理する. そのため, 本稿の主張は「未知種を安全に弾ける」ではなく, 「near-OOD に対する順位性能と FPR95 を改善した」に留めるべきである.

6.5 評価プロトコルの限界

本稿の現行結果は固定 split に基づく. 野生動物画像では, 背景, 撮影地点, カメラ機種, 時刻がラベルと相関する可能性があるため, 本来は camera-held-out split や location-held-out split による再評価が望ましい. しかし, 現在の prepared split には camera ID, event ID, location ID などのメタデータが含まれておらず, この split だけからこれらの追加評価を生成することはできなかった.

そのため, 本稿では固定 split 上の結論として範囲を限定し, 画像単位 bootstrap, OOD 種別解析, false accept 例, 距離設計 ablation を追加して, 主張の根拠と限界を明示する. DINOv2 seed=42 の画像単位 bootstrap では, MAF の AUROC 95% CI は [0.8878, 0.8965] であり, Energy や GEN の CI とは十分に離れていた. 一方, 背景・撮影地点への依存性および split 単位の頑健性は, metadata に基づく再分割が必要であり, 今後の検証課題として残る.

7 結論

本稿では, 野生動物 near-OOD 検知に対して, 凍結 vision backbone の特徴空間上で正則化 Mahalanobis 距離を用いる post-hoc score 設計を検証した. MAF は, ID validation set から推定したクラス平均と共有共分散に基づき, 全 ID クラスへの距離ベクトルを相対分布へ変換することで ID らしさを評価する一実装である. 5 ID 種と 5 OOD 種からなる固定 split の評価では, DINOv2-ViT-B/14 において MAF が AUROC 0.8922, FPR95 0.5157 を示し, ASH-P, SCALE, GEN, KNN, ViM などの非 Mahalanobis 系比較手法を上回った. ImageNet-ViT と OpenAI CLIP-B/16 でも Mahalanobis++ 型正規化を含む Mahalanobis 系設計が強く, 凍




図 4: α と confidence/consistency 成分の関係. DINOv2 と BioCLIP のいずれでも両成分は強く相関するが、融合係数により順位性能が変化する。

結特徴上のクラス幾何が野生動物 near-OOD に有効な場合があることを確認した。

一方で、MAF は全ての backbone で最良となる手法ではない。BioCLIP では GEN が AUROC で最良であり、DINOv2 でも AUTC では GEN が優位であった。また、DINOv2 では Mahalanobis++型 MAF が AUROC 0.8904 と競合的であり、ImageNet-ViT では Mahalanobis++型 MAF が通常の MAF を上回った。したがって、本稿の結論は「MAF が未知種を安全に棄却できる」ではなく、「凍結 DINOv2 など一部の特徴空間では、正則化 Mahalanobis 距離が near-OOD の順位性能と FPR95 を改善し、特徴正規化を含む Mahalanobis 系設計が有力な選択肢となる」という限定的なものである。今後は、metadata に基づく camera-held-out split や location-held-out split により、背景・撮影地点への依存性を検証する必要がある。

参考文献

- [1] Dan Hendrycks and Kevin Gimpel. A baseline for detecting misclassified and out-of-distribution examples in neural networks. In *International Conference on Learning Representations*, 2017.
- [2] Shiyu Liang, Yixuan Li, and R. Srikant. Enhancing the reliability of out-of-distribution image detection in neural networks. In *International Conference on Learning Representations*, 2018.
- [3] Weitang Liu, Xiaoyun Wang, John D. Owens, and Yixuan Li. Energy-based out-of-distribution detection. In *Advances in Neural Information Processing Systems*, pp. 21464–21475, 2020.
- [4] Xixi Liu, Yaroslava Lochman, and Christopher Zach. Gen: Pushing the limits of softmax-based out-of-distribution detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 23946–23955, 2023.
- [5] Kimin Lee, Kibok Lee, Honglak Lee, and Jinwoo Shin. A simple unified framework for detecting out-of-distribution samples and adversarial attacks. In *Advances in Neural Information Processing Systems*, 2018.
- [6] Jie Ren, Stanislav Fort, Jeremiah Z. Liu, Abhijit Guha Roy, Shreyas Padhy, and Balaji Lakshminarayanan. A simple fix to mahalanobis distance for improving near-ood detection. *arXiv preprint arXiv:2106.09022*, 2021.
- [7] Maximilian Müller and Matthias Hein. Mahalanobis++: Improving ood detection via feature normalization. In *Proceedings of the 42nd International Conference on Machine Learning*, 2025.
- [8] Yiyu Sun, Yifei Ming, Xiaojin Zhu, and Yixuan Li. Out-of-distribution detection with deep nearest neighbors. In *Proceedings of the 39th International Conference on Machine Learning*, pp. 20827–20840, 2022.
- [9] Haoqi Wang, Zhizhong Li, Litong Feng, and Wayne Zhang. Vim: Out-of-distribution with virtual-logit matching. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 4921–4930, 2022.
- [10] Yiyu Sun, Chuan Guo, and Yixuan Li. React: Out-of-distribution detection with rectified activations. In *Advances in Neural Information Processing Systems*, pp. 144–157, 2021.
- [11] Yiyu Sun and Yixuan Li. Dice: Leveraging sparsification for out-of-distribution detection. In *European Conference on Computer Vision*, pp. 691–708, 2022.
- [12] Andrija Djuricic, Nebojsa Bozanic, Arjun Ashok, and Rosanne Liu. Extremely simple activation shaping for out-of-distribution detection. In *International Conference on Learning Representations*, 2023.
- [13] Kai Xu, Rongyu Chen, Gianni Franchi, and Angela Yao. Scaling for training time and post-hoc out-of-distribution detection enhancement. In *International Conference on Learning Representations*, 2024.
- [14] Litian Liu and Yao Qin. Detecting out-of-distribution through the lens of neural collapse. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 15424–15433, 2025.




図 5: DINOv2 と BioCLIP における ID/OOD 種別の t-SNE 可視化. DINOv2 では ID クラスタが比較的まとまり, OOD 種は近傍 ID クラスタの周辺に配置される傾向がある.

- [15] Yifeng Yang, Lin Zhu, Zewen Sun, Hengyu Liu, Qinying Gu, and Nanyang Ye. Oodd: Test-time out-of-distribution detection with dynamic dictionary. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 30630–30639, 2025.
- [16] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning*, pp. 8748–8763, 2021.
- [17] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy V. Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mido Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jégou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*, 2024.
- [18] Samuel Stevens, Jiaman Wu, Matthew J. Thompson, Elizabeth G. Campolongo, Chan Hee Song, David Edward Carlyn, Li Dong, Wasila M. Dahdul, Charles Stewart, Tanya Berger-Wolf, Wei-Lun Chao, and Yu Su. Bioclip: A vision foundation model for the tree of life. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 19412–19424, 2024.
- [19] Olivier Ledoit and Michael Wolf. A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, Vol. 88, No. 2, pp. 365–411, 2004.

Figure 4. ID/OOD score distributions




図 6: DINOv2 と BioCLIP の ID/OOD score 分布. BioCLIP では ID/OOD の重なりが大きく, MAF より GEN や SCALE が有利になる理由を示唆する.




図 7: OOD 種ごとの nearest-ID 分布と MAF score 分布. leopard は cheetah, impala は giraffe, wildebeest は buffalo へ寄りやすい.



図 8: DINOv2 MAF で ID 95%受取閾値を超えた false accept 上位例。既知種に近い未知種が誤受取されやすい。

A 全 backbone における詳細結果

表 8-12 に、本文で要約した各 backbone の詳細結果を示す。値は seed 平均 $\pm$ 標準偏差である。表中では、列名の $\uparrow$ が高いほど良い指標、 $\downarrow$ が低いほど良い指標を表す。表中の値は、本文の主比較で用いた代表設定および明示した best-by-method 設定に対応する。したがって、source-default のみの再現表ではなく、本稿の主張に用いた比較結果の完全表として読むべきである。

DINOv2 では MAF が AUROC と FPR95 で強い一方、AUTC では GEN が最良である。また、Mahalanobis++ は MAF と極めて近く、MAF 単独の大幅な優位ではなく、Mahalanobis 距離に基づく設計が非 Mahalanobis 系 baseline より強いという解釈が妥当である。BioCLIP では GEN が AUROC で、SCALE が FPR95 で MAF を上回る。ImageNet-ViT では通常 MAF より Mahalanobis++ L2 MAF が高い AUROC と低い FPR95 を示す。OpenAI CLIP-B/16 でも通常 MAF と Mahalanobis++ L2 MAF は近く、正規化の効果は backbone ごとに異なる。ResNet50 は補助実験であり、MAF は最良ではないため、主張の中心には置かない。

表 8: DINOv2-ViT-B/14 における系統別詳細比較。値は 3 seed 平均 $\pm$ 標準偏差。列名の $\uparrow$ は高いほど良く、 $\downarrow$ は低いほど良いことを表す。

系統	手法	AUROC $\uparrow$	AUPR-IN $\uparrow$	AUPR-OUT $\uparrow$	FPR95 $\downarrow$	AUTC $\downarrow$
softmax/logit 系	MSP	0.7590 $\pm$ 0.0151	0.7162 $\pm$ 0.0193	0.7026 $\pm$ 0.0112	0.8319 $\pm$ 0.0062	0.9085 $\pm$ 0.0055
	Entropy	0.7896 $\pm$ 0.0133	0.7933 $\pm$ 0.0147	0.7362 $\pm$ 0.0091	0.8425 $\pm$ 0.0023	0.8928 $\pm$ 0.0048
	MaxLogit	0.8383 $\pm$ 0.0306	0.8270 $\pm$ 0.0325	0.8393 $\pm$ 0.0303	0.6025 $\pm$ 0.0484	0.8761 $\pm$ 0.0120
	Energy	0.8396 $\pm$ 0.0310	0.8275 $\pm$ 0.0327	0.8418 $\pm$ 0.0309	0.5841 $\pm$ 0.0538	0.8560 $\pm$ 0.0133
	GEN	0.7851 $\pm$ 0.0137	0.7920 $\pm$ 0.0131	0.7276 $\pm$ 0.0098	0.8557 $\pm$ 0.0045	0.7219 $\pm$ 0.0213
feature 系	KNN	0.7930 $\pm$ 0.0000	0.8065 $\pm$ 0.0000	0.7678 $\pm$ 0.0000	0.7277 $\pm$ 0.0000	0.8120 $\pm$ 0.0000
	ViM	0.7719 $\pm$ 0.0180	0.7999 $\pm$ 0.0266	0.7244 $\pm$ 0.0063	0.8403 $\pm$ 0.0113	0.9606 $\pm$ 0.0028
	OODD	0.7923 $\pm$ 0.0082	0.8185 $\pm$ 0.0102	0.7378 $\pm$ 0.0087	0.8377 $\pm$ 0.0195	0.7922 $\pm$ 0.0042
activation shaping 系	ReAct	0.8379 $\pm$ 0.0304	0.8268 $\pm$ 0.0386	0.8397 $\pm$ 0.0269	0.5743 $\pm$ 0.0443	0.8959 $\pm$ 0.0171
	DICE	0.7637 $\pm$ 0.0158	0.7609 $\pm$ 0.0195	0.7057 $\pm$ 0.0123	0.8721 $\pm$ 0.0072	0.8246 $\pm$ 0.0165
	ASH-B	0.7538 $\pm$ 0.0218	0.7275 $\pm$ 0.0205	0.7480 $\pm$ 0.0200	0.7575 $\pm$ 0.0225	0.9222 $\pm$ 0.0136
	ASH-P	0.8397 $\pm$ 0.0311	0.8278 $\pm$ 0.0325	0.8424 $\pm$ 0.0314	0.5837 $\pm$ 0.0544	0.8686 $\pm$ 0.0154
	SCALE	0.8355 $\pm$ 0.0309	0.8232 $\pm$ 0.0321	0.8367 $\pm$ 0.0313	0.6090 $\pm$ 0.0532	0.8875 $\pm$ 0.0130
	NCI	0.6930 $\pm$ 0.0150	0.7014 $\pm$ 0.0131	0.6494 $\pm$ 0.0106	0.8856 $\pm$ 0.0056	0.9196 $\pm$ 0.0031
Mahalanobis 系	Mah-MinDist	0.7761 $\pm$ 0.0000	0.7315 $\pm$ 0.0000	0.7695 $\pm$ 0.0000	0.7192 $\pm$ 0.0001	0.8741 $\pm$ 0.0000
	RMD	0.4748 $\pm$ 0.0000	0.4970 $\pm$ 0.0000	0.4788 $\pm$ 0.0000	0.9482 $\pm$ 0.0000	1.0044 $\pm$ 0.0000
	Mahalanobis++	0.8904 $\pm$ 0.0000	0.8976 $\pm$ 0.0000	0.8759 $\pm$ 0.0000	0.5217 $\pm$ 0.0004	0.7663 $\pm$ 0.0000
	MAF	0.8922 $\pm$ 0.0000	0.8994 $\pm$ 0.0000	0.8784 $\pm$ 0.0000	0.5157 $\pm$ 0.0001	0.7641 $\pm$ 0.0000

表 9: BioCLIP における詳細比較。値は 3 seed 平均 $\pm$ 標準偏差。列名の $\uparrow$ は高いほど良く、 $\downarrow$ は低いほど良いことを表す。

Method	Venue	AUROC $\uparrow$	AUPR-IN $\uparrow$	AUPR-OUT $\uparrow$	FPR95 $\downarrow$	AUTC $\downarrow$
GEN	CVPR 2023	0.8080 $\pm$ 0.0088	0.8122 $\pm$ 0.0082	0.7679 $\pm$ 0.0091	0.7804 $\pm$ 0.0135	0.7078 $\pm$ 0.0086
MAF $\alpha = 0.75$	ours	0.8031 $\pm$ 0.0000	0.8161 $\pm$ 0.0000	0.7724 $\pm$ 0.0000	0.7327 $\pm$ 0.0001	0.8490 $\pm$ 0.0000
SCALE	ICLR 2024	0.8015 $\pm$ 0.0112	0.8031 $\pm$ 0.0165	0.7841 $\pm$ 0.0079	0.7159 $\pm$ 0.0090	0.8771 $\pm$ 0.0056
ASH-S	ICLR 2023	0.8012 $\pm$ 0.0113	0.8028 $\pm$ 0.0166	0.7835 $\pm$ 0.0080	0.7166 $\pm$ 0.0093	0.8721 $\pm$ 0.0063
Energy	NeurIPS 2020	0.7980 $\pm$ 0.0117	0.8016 $\pm$ 0.0163	0.7761 $\pm$ 0.0085	0.7256 $\pm$ 0.0079	0.8796 $\pm$ 0.0058
MaxLogit	arXiv 2019	0.7980 $\pm$ 0.0118	0.8016 $\pm$ 0.0163	0.7778 $\pm$ 0.0087	0.7268 $\pm$ 0.0089	0.8765 $\pm$ 0.0062
ASH-P	ICLR 2023	0.7978 $\pm$ 0.0118	0.8015 $\pm$ 0.0164	0.7754 $\pm$ 0.0087	0.7263 $\pm$ 0.0073	0.8719 $\pm$ 0.0069
Entropy	standard	0.7953 $\pm$ 0.0058	0.8013 $\pm$ 0.0058	0.7549 $\pm$ 0.0070	0.7958 $\pm$ 0.0074	0.8107 $\pm$ 0.0071
MSP	ICLR wkshp. 2017	0.7931 $\pm$ 0.0056	0.8008 $\pm$ 0.0082	0.7476 $\pm$ 0.0068	0.8078 $\pm$ 0.0081	0.8374 $\pm$ 0.0045
Mahalanobis++ L2 MAF	ours-ablation	0.7927 $\pm$ 0.0000	0.8070 $\pm$ 0.0000	0.7582 $\pm$ 0.0000	0.7651 $\pm$ 0.0003	0.8507 $\pm$ 0.0000
ViM	CVPR 2022	0.7641 $\pm$ 0.0154	0.7838 $\pm$ 0.0197	0.7188 $\pm$ 0.0173	0.8136 $\pm$ 0.0241	0.9365 $\pm$ 0.0154
OODD	CVPR 2023	0.7339 $\pm$ 0.0199	0.7669 $\pm$ 0.0192	0.6756 $\pm$ 0.0220	0.8860 $\pm$ 0.0196	0.8168 $\pm$ 0.0210
DICE	ECCV 2022	0.6934 $\pm$ 0.0203	0.7213 $\pm$ 0.0243	0.6407 $\pm$ 0.0155	0.8994 $\pm$ 0.0075	0.8957 $\pm$ 0.0097
NCI	CVPR 2025	0.6887 $\pm$ 0.0210	0.6653 $\pm$ 0.0228	0.7039 $\pm$ 0.0143	0.7715 $\pm$ 0.0149	0.9193 $\pm$ 0.0060
Mah-MinDist	standard	0.6782 $\pm$ 0.0000	0.7059 $\pm$ 0.0000	0.6446 $\pm$ 0.0000	0.8884 $\pm$ 0.0000	0.9392 $\pm$ 0.0000
KNN	ICML 2022	0.6759 $\pm$ 0.0000	0.7247 $\pm$ 0.0000	0.6282 $\pm$ 0.0000	0.8855 $\pm$ 0.0000	0.8908 $\pm$ 0.0000
RMD	NeurIPS 2021	0.5277 $\pm$ 0.0000	0.6086 $\pm$ 0.0000	0.4786 $\pm$ 0.0000	0.9806 $\pm$ 0.0000	0.9438 $\pm$ 0.0000
ReAct	NeurIPS 2021	0.5000 $\pm$ 0.0000	0.5000 $\pm$ 0.0000	0.5000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000
ASH-B	ICLR 2023	0.3663 $\pm$ 0.0286	0.4144 $\pm$ 0.0147	0.4117 $\pm$ 0.0171	0.9827 $\pm$ 0.0060	1.0576 $\pm$ 0.0141

B MAF と Mahalanobis++ 型正規化の差分

MAF の性能が特徴正規化だけで説明できるかを確認するため、通常特徴上の MAF と、特徴を L2 正規化してから同じ MAF を適用する Mahalanobis++ L2 MAF を比較した。DINOv2 では通常 MAF の AUROC は 0.8922、Mahalanobis++ L2 MAF は 0.8904 であり、FPR95 も通常 MAF 0.5157、Mahalanobis++ L2 MAF 0.5217 であった。一方、ImageNet-ViT では通常 MAF 0.8453 に対して Mahalanobis++ L2 MAF 0.8598 であり、OpenAI CLIP-B/16 でも両者はほぼ同等であった。BioCLIP では通常 MAF が Mahalanobis++ L2 MAF を上回るが、AUROC では GEN が通常 MAF を上回る。したがって、MAF は Mahalanobis++ の一貫した上位互換ではない。

表 13 と図 9 に、DINOv2 での OOD 種別差分を示す。leopard では通常 MAF が AUROC を 0.0067 改善し、rhino と wildebeest では FPR95 をそれぞれ 0.0138、0.0095 改善した。一方、impala では Mahalanobis++ L2 MAF が AUROC でわずかに上回る。

表 10: ImageNet-ViT における詳細比較. 値は 3 seed 平均 $\pm$ 標準偏差. 列名の $\uparrow$ は高いほど良く, $\downarrow$ は低いほど良いことを表す.

Method	Venue	AUROC $\uparrow$	AUPR-IN $\uparrow$	AUPR-OUT $\uparrow$	FPR95 $\downarrow$	AUTC $\downarrow$
Mahalanobis++ L2 MAF	ours-ablation	0.8598 $\pm$ 0.0000	0.8745 $\pm$ 0.0000	0.8339 $\pm$ 0.0000	0.6186 $\pm$ 0.0004	0.7990 $\pm$ 0.0002
MAF $\alpha = 0.75$	ours	0.8453 $\pm$ 0.0000	0.8633 $\pm$ 0.0000	0.8145 $\pm$ 0.0000	0.6739 $\pm$ 0.0004	0.8152 $\pm$ 0.0002
ASH-P	ICLR 2023	0.8091 $\pm$ 0.0228	0.8013 $\pm$ 0.0175	0.7970 $\pm$ 0.0388	0.6849 $\pm$ 0.0835	0.8800 $\pm$ 0.0097
Energy	NeurIPS 2020	0.8090 $\pm$ 0.0226	0.8010 $\pm$ 0.0173	0.7969 $\pm$ 0.0385	0.6855 $\pm$ 0.0827	0.8875 $\pm$ 0.0149
MaxLogit	arXiv 2019	0.8073 $\pm$ 0.0228	0.8003 $\pm$ 0.0172	0.7936 $\pm$ 0.0409	0.6951 $\pm$ 0.0813	0.8860 $\pm$ 0.0167
ASH-S	ICLR 2023	0.8070 $\pm$ 0.0234	0.7993 $\pm$ 0.0172	0.7949 $\pm$ 0.0416	0.6967 $\pm$ 0.0819	0.8823 $\pm$ 0.0146
SCALE	ICLR 2024	0.8068 $\pm$ 0.0232	0.7988 $\pm$ 0.0170	0.7949 $\pm$ 0.0414	0.6966 $\pm$ 0.0819	0.8872 $\pm$ 0.0186
GEN	CVPR 2023	0.7907 $\pm$ 0.0058	0.8028 $\pm$ 0.0024	0.7411 $\pm$ 0.0061	0.8179 $\pm$ 0.0133	0.6785 $\pm$ 0.0089
Entropy	standard	0.7874 $\pm$ 0.0096	0.7989 $\pm$ 0.0060	0.7393 $\pm$ 0.0081	0.8247 $\pm$ 0.0053	0.8089 $\pm$ 0.0125
MSP	ICLR wkshp. 2017	0.7825 $\pm$ 0.0110	0.7749 $\pm$ 0.0112	0.7317 $\pm$ 0.0100	0.8345 $\pm$ 0.0083	0.8405 $\pm$ 0.0092
KNN	ICML 2022	0.7644 $\pm$ 0.0000	0.7796 $\pm$ 0.0000	0.7434 $\pm$ 0.0000	0.7682 $\pm$ 0.0000	0.8410 $\pm$ 0.0000
OODD	CVPR 2023	0.7639 $\pm$ 0.0100	0.7872 $\pm$ 0.0138	0.7139 $\pm$ 0.0060	0.8476 $\pm$ 0.0083	0.8173 $\pm$ 0.0160
ViM	CVPR 2022	0.7522 $\pm$ 0.0013	0.7716 $\pm$ 0.0109	0.7046 $\pm$ 0.0108	0.8694 $\pm$ 0.0243	0.9760 $\pm$ 0.0027
DICE	ECCV 2022	0.7436 $\pm$ 0.0074	0.7652 $\pm$ 0.0053	0.6850 $\pm$ 0.0119	0.8745 $\pm$ 0.0216	0.8565 $\pm$ 0.0056
Mah-MinDist	standard	0.7273 $\pm$ 0.0000	0.7592 $\pm$ 0.0000	0.6874 $\pm$ 0.0000	0.8494 $\pm$ 0.0000	0.9306 $\pm$ 0.0000
RMD	NeurIPS 2021	0.5947 $\pm$ 0.0000	0.6336 $\pm$ 0.0000	0.5381 $\pm$ 0.0000	0.9641 $\pm$ 0.0000	0.9712 $\pm$ 0.0000
NCI	CVPR 2025	0.5430 $\pm$ 0.0740	0.5040 $\pm$ 0.0592	0.6083 $\pm$ 0.0380	0.8216 $\pm$ 0.0087	0.9775 $\pm$ 0.0265
ReAct	NeurIPS 2021	0.5000 $\pm$ 0.0000	0.5000 $\pm$ 0.0000	0.5000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000
ASH-B	ICLR 2023	0.3182 $\pm$ 0.0304	0.3941 $\pm$ 0.0133	0.3859 $\pm$ 0.0193	0.9908 $\pm$ 0.0104	1.0922 $\pm$ 0.0229

表 11: OpenAI CLIP-B/16 における詳細比較. 値は 3 seed 平均 $\pm$ 標準偏差. 列名の $\uparrow$ は高いほど良く, $\downarrow$ は低いほど良いことを表す.

Method	Venue	AUROC $\uparrow$	AUPR-IN $\uparrow$	AUPR-OUT $\uparrow$	FPR95 $\downarrow$	AUTC $\downarrow$
Mahalanobis++ L2 MAF	ours-ablation	0.8315 $\pm$ 0.0000	0.8389 $\pm$ 0.0000	0.8081 $\pm$ 0.0000	0.6821 $\pm$ 0.0003	0.8231 $\pm$ 0.0001
MAF $\alpha = 0.75$	ours	0.8301 $\pm$ 0.0000	0.8382 $\pm$ 0.0000	0.8063 $\pm$ 0.0000	0.6850 $\pm$ 0.0003	0.8217 $\pm$ 0.0001
GEN	CVPR 2023	0.7971 $\pm$ 0.0028	0.8078 $\pm$ 0.0097	0.7556 $\pm$ 0.0073	0.8050 $\pm$ 0.0167	0.7143 $\pm$ 0.0031
Entropy	standard	0.7836 $\pm$ 0.0051	0.7949 $\pm$ 0.0084	0.7416 $\pm$ 0.0072	0.8140 $\pm$ 0.0100	0.8187 $\pm$ 0.0053
ASH-S	ICLR 2023	0.7833 $\pm$ 0.0024	0.7735 $\pm$ 0.0043	0.7720 $\pm$ 0.0072	0.7315 $\pm$ 0.0151	0.8719 $\pm$ 0.0036
SCALE	ICLR 2024	0.7833 $\pm$ 0.0024	0.7735 $\pm$ 0.0043	0.7720 $\pm$ 0.0072	0.7315 $\pm$ 0.0151	0.8718 $\pm$ 0.0036
ASH-P	ICLR 2023	0.7832 $\pm$ 0.0022	0.7739 $\pm$ 0.0045	0.7699 $\pm$ 0.0060	0.7242 $\pm$ 0.0113	0.8745 $\pm$ 0.0029
MSP	ICLR wkshp. 2017	0.7806 $\pm$ 0.0052	0.7838 $\pm$ 0.0083	0.7340 $\pm$ 0.0063	0.8229 $\pm$ 0.0039	0.8472 $\pm$ 0.0017
Energy	NeurIPS 2020	0.7801 $\pm$ 0.0047	0.7702 $\pm$ 0.0101	0.7650 $\pm$ 0.0039	0.7308 $\pm$ 0.0003	0.8768 $\pm$ 0.0046
MaxLogit	arXiv 2019	0.7790 $\pm$ 0.0051	0.7698 $\pm$ 0.0102	0.7645 $\pm$ 0.0047	0.7437 $\pm$ 0.0031	0.8742 $\pm$ 0.0055
OODD	CVPR 2023	0.7515 $\pm$ 0.0109	0.7690 $\pm$ 0.0093	0.6857 $\pm$ 0.0119	0.8965 $\pm$ 0.0113	0.7962 $\pm$ 0.0137
ViM	CVPR 2022	0.7314 $\pm$ 0.0600	0.7433 $\pm$ 0.0594	0.6764 $\pm$ 0.0742	0.8560 $\pm$ 0.1065	0.9993 $\pm$ 0.0014
DICE	ECCV 2022	0.6902 $\pm$ 0.0109	0.7184 $\pm$ 0.0088	0.6289 $\pm$ 0.0074	0.9157 $\pm$ 0.0022	0.8897 $\pm$ 0.0037
KNN	ICML 2022	0.6865 $\pm$ 0.0000	0.6687 $\pm$ 0.0000	0.6747 $\pm$ 0.0000	0.8352 $\pm$ 0.0000	0.9224 $\pm$ 0.0000
NCI	CVPR 2025	0.6855 $\pm$ 0.0174	0.6358 $\pm$ 0.0234	0.7079 $\pm$ 0.0182	0.7571 $\pm$ 0.0161	0.9172 $\pm$ 0.0069
Mah-MinDist	standard	0.6791 $\pm$ 0.0000	0.6714 $\pm$ 0.0000	0.6493 $\pm$ 0.0000	0.8785 $\pm$ 0.0000	0.9649 $\pm$ 0.0000
ReAct	NeurIPS 2021	0.5000 $\pm$ 0.0000	0.5000 $\pm$ 0.0000	0.5000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000
RMD	NeurIPS 2021	0.4956 $\pm$ 0.0000	0.5494 $\pm$ 0.0000	0.4702 $\pm$ 0.0000	0.9696 $\pm$ 0.0000	0.9889 $\pm$ 0.0000
ASH-B	ICLR 2023	0.3557 $\pm$ 0.0242	0.4150 $\pm$ 0.0126	0.3968 $\pm$ 0.0122	0.9952 $\pm$ 0.0031	1.0702 $\pm$ 0.0111

表 12: ResNet50 補助実験における詳細比較. ResNet50 の MAF/RMD 系は共通 projection 特徴で評価した. 値は 4 seed 平均 $\pm$ 標準偏差.

Method	Venue	AUROC $\uparrow$	AUPR-IN $\uparrow$	AUPR-OUT $\uparrow$	FPR95 $\downarrow$	AUTC $\downarrow$
ASH-P	ICLR 2023	0.8185 $\pm$ 0.0038	0.8197 $\pm$ 0.0055	0.8037 $\pm$ 0.0065	0.6950 $\pm$ 0.0183	0.8580 $\pm$ 0.0073
SCALE	ICLR 2024	0.8191 $\pm$ 0.0030	0.8199 $\pm$ 0.0047	0.8044 $\pm$ 0.0050	0.6969 $\pm$ 0.0152	0.8571 $\pm$ 0.0062
Energy	NeurIPS 2020	0.8190 $\pm$ 0.0037	0.8199 $\pm$ 0.0051	0.8047 $\pm$ 0.0057	0.6925 $\pm$ 0.0174	0.8578 $\pm$ 0.0073
MaxLogit	arXiv 2019	0.8186 $\pm$ 0.0035	0.8198 $\pm$ 0.0051	0.8033 $\pm$ 0.0051	0.6989 $\pm$ 0.0148	0.8567 $\pm$ 0.0077
ASH-S	ICLR 2023	0.8178 $\pm$ 0.0033	0.8177 $\pm$ 0.0043	0.8029 $\pm$ 0.0059	0.6997 $\pm$ 0.0168	0.8689 $\pm$ 0.0072
GEN	CVPR 2023	0.8146 $\pm$ 0.0013	0.8226 $\pm$ 0.0034	0.7735 $\pm$ 0.0032	0.7820 $\pm$ 0.0106	0.6910 $\pm$ 0.0047
Entropy	standard	0.8144 $\pm$ 0.0025	0.8230 $\pm$ 0.0051	0.7734 $\pm$ 0.0028	0.7822 $\pm$ 0.0084	0.8579 $\pm$ 0.0027
MSP	ICLR wkshp. 2017	0.8065 $\pm$ 0.0023	0.7924 $\pm$ 0.0036	0.7622 $\pm$ 0.0033	0.7829 $\pm$ 0.0072	0.8787 $\pm$ 0.0022
Mah-MinDist	standard	0.7954 $\pm$ 0.0041	0.7938 $\pm$ 0.0062	0.7795 $\pm$ 0.0024	0.7471 $\pm$ 0.0113	0.9759 $\pm$ 0.0169
OODD	CVPR 2023	0.7851 $\pm$ 0.0095	0.8043 $\pm$ 0.0086	0.7480 $\pm$ 0.0168	0.8091 $\pm$ 0.0261	0.7796 $\pm$ 0.0165
NCI	CVPR 2025	0.7585 $\pm$ 0.0144	0.7174 $\pm$ 0.0325	0.7668 $\pm$ 0.0089	0.7087 $\pm$ 0.0129	0.8694 $\pm$ 0.0177
ViM	CVPR 2022	0.7560 $\pm$ 0.0238	0.7908 $\pm$ 0.0209	0.7009 $\pm$ 0.0341	0.8489 $\pm$ 0.0378	0.9400 $\pm$ 0.0213
MAF $\alpha = 0.75$	ours	0.7368 $\pm$ 0.0080	0.7124 $\pm$ 0.0061	0.7391 $\pm$ 0.0053	0.7683 $\pm$ 0.0161	0.9092 $\pm$ 0.0047
DICE	ECCV 2022	0.7366 $\pm$ 0.0055	0.7652 $\pm$ 0.0023	0.6720 $\pm$ 0.0074	0.8918 $\pm$ 0.0065	0.8790 $\pm$ 0.0070
KNN	ICML 2022	0.6645 $\pm$ 0.0000	0.6538 $\pm$ 0.0000	0.6606 $\pm$ 0.0000	0.8372 $\pm$ 0.0000	0.9163 $\pm$ 0.0000
ReAct	NeurIPS 2021	0.5000 $\pm$ 0.0000	0.5000 $\pm$ 0.0000	0.5000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000	1.0000 $\pm$ 0.0000
ASH-B	ICLR 2023	0.4908 $\pm$ 0.0292	0.5371 $\pm$ 0.0492	0.4802 $\pm$ 0.0158	0.9656 $\pm$ 0.0103	1.0030 $\pm$ 0.0106
RMD	NeurIPS 2021	0.4226 $\pm$ 0.0463	0.4180 $\pm$ 0.0197	0.5312 $\pm$ 0.0320	0.8447 $\pm$ 0.0150	1.0032 $\pm$ 0.0039

この結果から、本稿では MAF を「常に最良となる正規化手法」ではなく、Mahalanobis 距離を全 ID クラスへの距離分布として扱い、near-OOD がどの ID クラスへ吸収されやすいかを解析する枠組みとして位置づける。

表 13: DINOv2 における通常 MAF と Mahalanobis++ L2 MAF の OOD 種別差分. ΔFPR95 は Mahalanobis++ L2 MAF から通常 MAF を引いた値で、正なら通常 MAF の誤受理が少ない。

OOD	MAF AUROC $\uparrow$	L2 MAF AUROC $\uparrow$	ΔAUROC	MAF FPR95 $\downarrow$	L2 MAF FPR95 $\downarrow$	ΔFPR95
impala	0.9217	0.9219	-0.0002	0.4260	0.4305	+0.0045
leopard	0.7865	0.7798	+0.0067	0.6645	0.6663	+0.0018
lion	0.9704	0.9704	0.0000	0.1623	0.1627	+0.0003
rhino	0.9316	0.9304	+0.0011	0.4807	0.4945	+0.0138
wildebeest	0.8510	0.8493	+0.0017	0.8450	0.8545	+0.0095




図 9: DINOv2 における通常 MAF と Mahalanobis++ L2 MAF の OOD 種別差分. 左は AUROC 差分, 右は FPR95 改善量を示す. 青は通常 MAF が有利な方向, 赤は Mahalanobis++ L2 MAF が有利な方向である。

C Oracle 的な hyperparameter sweep による確認

表 14 に、主要な競合手法について、percentile や α などの hyperparameter を test OOD 上で探索した diagnostic best-by-method の結果を示す。これは実運用可能な model selection ではなく、競合手法に有利な oracle 的上限確認である。したがって本文の主比較には用いず、source-default 設定だけで競合手法を不利にしていなかったかを確認する補助結果として扱う。

DINOv2 では、ReAct や ASH-P を test OOD に合わせて選んでも AUROC は 0.8379–0.8397 であり、MAF $\alpha = 0.75$ の 0.8922 および Mahalanobis++ L2 MAF の 0.8904 には届かない。ImageNet-ViT でも、ASH-P の diagnostic best は 0.8091、ReAct は 0.7742 であり、通常 MAF の 0.8453 および Mahalanobis++ L2 MAF の 0.8598 を下回る。OpenAI CLIP-B/16 でも、GEN が 0.7971、ReAct が 0.7650 であり、MAF 系の 0.830 前後には届かない。一方、BioCLIP では GEN が 0.8080 で MAF $\alpha = 0.75$ の 0.8031 を上回るため、本文と同様に MAF が全 backbone で最良とは主張しない。

D DINOv3 による追加確認

表 15 に、DINOv3 を用いた補助実験を示す。DINOv3-L/16 384 px five-crop では、固定 $\alpha = 0.75$ の MAF が AUROC 0.9392、FPR95 0.3280 に達し、DINOv2 の結果を大きく上回った。ただし、DINOv3-Huge+ では Euclidean fusion が最良となるため、本結果は MAF そのものの一般的優位ではなく、DINOv3 特徴上で距離ベース score が強くなることを示す補助結果として扱う。

図 10 に、代表設定の score 分布と α sweep を示す。固定 $\alpha = 0.75$ は best $\alpha = 0.63$ とほぼ同等であった。

E Split 公開と撮影条件に関する制約

本研究では、各 split に十分な枚数を確保し、ID/OOD ともに 1 万枚規模の評価を行った。また、データセットと split を https://drive.google.com/drive/folders/1LCdZnAN6gWIV_Ds0bTWLipD6jjptLAgj?usp=share_link で公開し、実験コードと生成済み論文 PDF を <https://github.com/omotes24/MAF01> で公開することで、再現性と第三者による検証可能性を担保する。ただし、現行の prepared split には camera ID や location ID が含まれていないため、背景や撮影地点の影響が評価に残る可能性がある。今後は metadata を整備し、camera-held-out および location-held-out 設定でも同様の傾向が得られるかを検証する。

表 14: 競合手法の oracle 的 diagnostic sweep 結果. 値は 3 seed 平均 $\pm$ 標準偏差. setting は選択された hyperparameter を示す. test OOD を用いた best-by-method であるため, 主比較ではなく上限確認として扱う.

Backbone	Method	Setting	AUROC $\uparrow$	AUPR-OUT $\uparrow$	FPR95 $\downarrow$
BioCLIP	GEN	source $\gamma = 0.1$	0.8080 $\pm$ 0.0088	0.7679 $\pm$ 0.0091	0.7804 $\pm$ 0.0135
	ASH-S	oracle $p = 65$	0.8015 $\pm$ 0.0112	0.7841 $\pm$ 0.0079	0.7159 $\pm$ 0.0090
	SCALE	oracle $p = 50$	0.8015 $\pm$ 0.0112	0.7841 $\pm$ 0.0079	0.7159 $\pm$ 0.0090
	ASH-P	source $p = 65$	0.7980 $\pm$ 0.0117	0.7761 $\pm$ 0.0085	0.7256 $\pm$ 0.0079
	ReAct	oracle $p = 99$	0.7901 $\pm$ 0.0128	0.7613 $\pm$ 0.0090	0.7533 $\pm$ 0.0072
	ViM	source dim rule	0.7641 $\pm$ 0.0154	0.7188 $\pm$ 0.0173	0.8136 $\pm$ 0.0241
	NCI	oracle $\alpha = 0.01$	0.7333 $\pm$ 0.0203	0.7071 $\pm$ 0.0120	0.8146 $\pm$ 0.0156
	ASH-B	oracle $p = 95$	0.7083 $\pm$ 0.0068	0.6400 $\pm$ 0.0101	0.9262 $\pm$ 0.0167
	DICE	oracle $p = 50$	0.6936 $\pm$ 0.0204	0.6410 $\pm$ 0.0155	0.8993 $\pm$ 0.0075
DINOv2	ASH-P	oracle $p = 85$	0.8397 $\pm$ 0.0311	0.8424 $\pm$ 0.0314	0.5837 $\pm$ 0.0544
	ReAct	oracle $p = 99$	0.8379 $\pm$ 0.0304	0.8397 $\pm$ 0.0269	0.5743 $\pm$ 0.0443
	ASH-S	oracle $p = 85$	0.8357 $\pm$ 0.0310	0.8372 $\pm$ 0.0318	0.6082 $\pm$ 0.0549
	SCALE	source $p = 85$	0.8355 $\pm$ 0.0309	0.8367 $\pm$ 0.0313	0.6090 $\pm$ 0.0532
	GEN	source $\gamma = 0.1$	0.7851 $\pm$ 0.0137	0.7276 $\pm$ 0.0098	0.8557 $\pm$ 0.0045
	ViM	source dim rule	0.7719 $\pm$ 0.0180	0.7244 $\pm$ 0.0063	0.8403 $\pm$ 0.0113
	DICE	oracle $p = 99$	0.7637 $\pm$ 0.0158	0.7057 $\pm$ 0.0123	0.8721 $\pm$ 0.0072
	ASH-B	oracle $p = 99$	0.7538 $\pm$ 0.0218	0.7480 $\pm$ 0.0200	0.7575 $\pm$ 0.0225
	NCI	oracle $\alpha = 0.01$	0.6930 $\pm$ 0.0150	0.6494 $\pm$ 0.0106	0.8856 $\pm$ 0.0056
ImageNet-ViT	ASH-P	oracle $p = 90$	0.8091 $\pm$ 0.0228	0.7970 $\pm$ 0.0388	0.6849 $\pm$ 0.0835
	SCALE	oracle $p = 95$	0.8072 $\pm$ 0.0241	0.7949 $\pm$ 0.0422	0.6965 $\pm$ 0.0817
	ASH-S	source $p = 90$	0.8070 $\pm$ 0.0234	0.7949 $\pm$ 0.0416	0.6967 $\pm$ 0.0819
	GEN	source $\gamma = 0.1$	0.7907 $\pm$ 0.0058	0.7411 $\pm$ 0.0061	0.8179 $\pm$ 0.0133
	ReAct	oracle $p = 99$	0.7742 $\pm$ 0.0133	0.7606 $\pm$ 0.0206	0.7486 $\pm$ 0.0366
	DICE	oracle $p = 99$	0.7566 $\pm$ 0.0275	0.6973 $\pm$ 0.0325	0.8641 $\pm$ 0.0363
	ViM	source dim rule	0.7522 $\pm$ 0.0013	0.7046 $\pm$ 0.0108	0.8694 $\pm$ 0.0243
	ASH-B	oracle $p = 99$	0.7504 $\pm$ 0.0114	0.7170 $\pm$ 0.0221	0.8146 $\pm$ 0.0314
	NCI	oracle $\alpha = 0.01$	0.6995 $\pm$ 0.0256	0.6596 $\pm$ 0.0218	0.8706 $\pm$ 0.0205
OpenAI CLIP-B/16	GEN	source $\gamma = 0.1$	0.7971 $\pm$ 0.0028	0.7556 $\pm$ 0.0073	0.8050 $\pm$ 0.0167
	ASH-S	source $p = 90$	0.7833 $\pm$ 0.0024	0.7720 $\pm$ 0.0072	0.7315 $\pm$ 0.0151
	SCALE	oracle $p = 90$	0.7833 $\pm$ 0.0024	0.7720 $\pm$ 0.0072	0.7315 $\pm$ 0.0151
	ASH-P	oracle $p = 90$	0.7832 $\pm$ 0.0022	0.7699 $\pm$ 0.0060	0.7242 $\pm$ 0.0113
	ReAct	oracle $p = 99$	0.7650 $\pm$ 0.0025	0.7447 $\pm$ 0.0077	0.7570 $\pm$ 0.0165
	ViM	source dim rule	0.7314 $\pm$ 0.0600	0.6764 $\pm$ 0.0742	0.8560 $\pm$ 0.1065
	NCI	oracle $\alpha = 0.01$	0.7305 $\pm$ 0.0108	0.7228 $\pm$ 0.0103	0.7844 $\pm$ 0.0092
	ASH-B	oracle $p = 95$	0.7145 $\pm$ 0.0011	0.6543 $\pm$ 0.0047	0.9044 $\pm$ 0.0063
	DICE	source $p = 90$	0.6904 $\pm$ 0.0111	0.6291 $\pm$ 0.0075	0.9156 $\pm$ 0.0022

表 15: DINOv3 による追加確認. best α および Euclidean fusion は test OOD を用いた diagnostic 結果である. 列名の $\uparrow$ は高いほど良く, $\downarrow$ は低いほど良いことを表す.

Backbone / setting	Score	AUROC $\uparrow$	AUPR-IN $\uparrow$	AUPR-OUT $\uparrow$	FPR95 $\downarrow$	AUTC $\downarrow$
DINOv3-L/16 384 five-crop	MAF $\alpha = 0.75$	0.9392	0.9412	0.9360	0.3280	0.7014
DINOv3-L/16 384 five-crop	MAF best $\alpha = 0.63$	0.9393	0.9416	0.9358	0.3249	0.7054
DINOv3-Huge+ 224 center	MAF $\alpha = 0.75$	0.9368	0.9470	0.9226	0.3730	0.6719
DINOv3-Huge+ 224 center	Euclidean fusion $\alpha = 0.75$	0.9418	0.9573	0.9092	0.4392	0.3926
DINOv3-L/16 384 center	MAF $\alpha = 0.75$	0.9246	0.9302	0.9149	0.4082	0.7089
DINOv3-B/16 384 center	MAF $\alpha = 0.75$	0.8989	0.9077	0.8854	0.5086	0.7621




図 10: DINOv3-L/16 384 px five-crop における MAF score 分布と α sweep. 左は固定 $\alpha = 0.75$ での ID/OOD score 分布, 右は AUROC- α 曲線である.